



RÉPUBLIQUE DU SÉNÉGAL

Un Peuple– Un But– Une Foi



MINISTÈRE DE L'ENSEIGNEMENT SUPÉRIEUR, DE LA RECHERCHE ET DE L'INNOVATION



Université Iba Der Thiam de Thiès

UFRSciences Et Technologies

Master Informatique

Option: Intelligence Artificielle et Smart-Tech

Université de Technologie de Troyes

Master(DNM) Sciences, Technologie et Santé
mention Ingénierie des Systèmes Complexes

Parcours Option Intelligence Artificielle et
Smart-Tech

THÈME: DÉTECTION ET PRÉDICTION DES INONDATIONS AU SÉNÉGAL PAR INTELLIGENCE ARTIFICIELLE : APPROCHE INTÉGRÉE BASÉE SUR LE MACHINE LEARNING, LE DEEP LEARNING ET LA PARTICIPATION CITOYENNE

Mémoire de fin d'études

Présenté en vue de l'obtention du diplôme d'ingénieur par

Papa Ahmadou Seydou Sow

soutenu publiquement le 16/ 02/ 2026 devant le jury composé de:

Président	Pr. Idrissa Gaye	UIDT
Examineur	Dr. François KALY	UIDT
Encadrant	Pr. Ibrahima Gueye	EPT

Année académique 2023-2024

Dédicace

Je dédie ce mémoire à mes parents, pour leur affection, leurs prières et leur soutien indéfectible.

*À mes frères et amis, **Momar, Saliou, Ababacar, Aly et Assane**, pour leur présence constante, leur fraternité et les sacrifices consentis pour ma réussite.*

*À mes fidèles compagnons de route : **Mor Lo Mbaye, Khalifa Babacar Wone, Aliou Gning**.
Merci pour la fraternité et la solidarité qui nous ont unis. Ce travail est aussi le vôtre.*

*À **Mami Rokhaya Mbaye**, pour son soutien précieux, sa bienveillance et ses conseils avisés qui m'ont été d'un grand secours tout au long de ce parcours.*

*Je le dédie également à l'ensemble des membres de ma famille, à mes amis de la **chambre B2** de l'Hôtel du Rail, ainsi qu'à ceux de **Master House**.*

*Enfin, je l'adresse à mes camarades et condisciples de **I'UFR SET**, en particulier ceux du **Département Informatique**.*

Remerciements

Au terme de ce travail, il me tient à cœur d'exprimer ma profonde gratitude à toutes les autorités académiques et aux personnes qui, de près ou de loin, ont contribué à la réalisation de ce mémoire. Leur disponibilité, leurs conseils avisés et leurs encouragements constants ont constitué un soutien précieux tout au long de ce parcours.

*Mes sincères remerciements vont au **Professeur Mamadou Babacar NDIAYE**, Recteur de l'Université Iba Der Thiam de Thiès (UIDT), pour son engagement en faveur de l'excellence académique et les efforts déployés afin d'offrir aux étudiants un cadre propice au développement intellectuel et scientifique.*

*J'exprime également ma reconnaissance au **Professeur Mouhamadou THIAM**, Directeur de l'UFR Sciences et Technologies (UFR SET), pour son implication constante et son attachement à la qualité de la formation.*

*Mes remerciements vont à **Docteur François Kaly**, Chef du Département, et à **Professeur Idrissa Gaye**, responsable du Master, pour leur engagement dans la coordination et le bon déroulement de la formation, ainsi que pour la rigueur et la transparence du processus d'admission au Master.*

*Je tiens également à remercier **Monsieur Babiga Birregah**, coordinateur du Master à l'Université de Technologie de Troyes (UTT), pour son implication dans le cadre de la co-diplomation et sa contribution au bon déroulement du programme.*

*Je tiens également à exprimer ma profonde gratitude au **Campus Franco-Sénégalais (CFS)**, dont la bourse m'a permis de poursuivre ce Master privé dans des conditions favorables. Ce soutien a constitué un levier déterminant dans la réalisation de ce parcours académique.*

*J'adresse mes sincères remerciements au **Professeur Ibrahima GUEYE**, enseignant-chercheur à l'École Polytechnique de Thiès (EPT), pour son encadrement rigoureux, la qualité de ses orientations scientifiques et sa disponibilité tout au long de ce travail.*

Je remercie également les équipes pédagogiques de l'Université Iba Der Thiam de Thiès (UIDT) et de l'Université de Technologie de Troyes (UTT), ainsi que l'ensemble des enseignants intervenant dans le Master en Intelligence Artificielle et Smart-Tech, pour la qualité de la formation dispensée dans le cadre de cette co-diplomation.

Enfin, je remercie mes camarades de promotion pour l'esprit d'entraide, avec une mention spéciale à Mamadou Cissokho pour la richesse de nos échanges,

SIGLES ET ABRÉVIATIONS

ANACIM : Agence Nationale de l'Aviation Civile et de la Météorologie

AUC-ROC : Area Under the Receiver Operating Characteristic Curve

API : Application Programming Interface

CNN : Convolutional Neural Network

CV : Cross-Validation

DL : Deep Learning

FN : Faux Négatif

FP : Faux Positif

F1-Score : Harmonic Mean of Precision and Recall

FCFA : Franc de la Communauté Financière Africaine

GIEC : Groupe d'experts intergouvernemental sur l'évolution du climat

GPU : Graphics Processing Unit

Grad-CAM : Gradient-weighted Class Activation Mapping

IA : Intelligence Artificielle

L2 : Régularisation de Tikhonov

LR : Learning Rate

LSTM : Long Short-Term Memory

ML : Machine Learning

ONAS : Office National de l'Assainissement du Sénégal

ONU : Organisation des Nations Unies

Open-Meteo : Plateforme de données météorologiques historiques

PDGI : Programme Décennal de Gestion des Inondations

PGIIS : Plan de Gestion Intégrée des Inondations du Sénégal

PR : Precision-Recall

RF : Random Forest

ROC : Receiver Operating Characteristic

SAR : Synthetic Aperture Radar

SMOTE : Synthetic Minority Over-sampling Technique

SVM : Support Vector Machine

TP : True Positive

TN : True Negative

UIDT : Université Iba Der Thiam de Thiès

UTT : Université de Technologie de Troyes

Liste Des Figures

- Figure 2.1** : Séries temporelles des précipitations journalières par zone (2005–2025)
Figure 2.2 : Distribution des précipitations journalières et seuils-proxy d'inondation (P97 et P95 sur 3 jours)
Figure 2.3 : Exemples représentatifs du dataset (inondation vs normale)
Figure 3.1 : Courbes ROC et Précision–Rappel du modèle Random Forest (test 2023–2025)
Figure 3.2 : Distribution des probabilités prédites et seuil de décision (0,350)
Figure 3.3 : Importance des variables (Gini) et courbe cumulative
Figure 3.4 : Matrice de confusion du modèle Random Forest
Figure 3.5 : Comparaison des performances des quatre architectures (barres + ROC)
Figure 3.6 : Courbes d'apprentissage (loss et accuracy) – 4 modèles, 3 phases
Figure 3.7 : Matrices de confusion comparatives des quatre architectures
Figure 3.8 : Visualisations Grad-CAM comparatives
Figure 3.9 : Pipeline opérationnel du système (RF → ConvNeXt → Alerte)
Figure C.1 : Interface de signalement d'une inondation par un citoyen
Figure C.2 : Résultat de la classification visuelle par ConvNeXt-Tiny
Figure C.3 : Tableau de bord des autorités locales
Figure C.4 : Validation d'un signalement par une autorité
Figure C.5 : Interface cartographique – alertes et couches géographiques
Figure C.6 : Prédiction automatique du risque d'inondation (Random Forest intégré)

Liste Des Tableaux

Tableau I.1 : Objectifs spécifiques et critères de succès
Tableau I.2 : Synthèse des principaux résultats
Tableau I.3 : Organisation du mémoire
Tableau 1.1 : Zones d'exposition aux inondations et mécanismes associés
Tableau 1.2 : Travaux de référence utilisant Random Forest
Tableau 1.3 : Évolution des architectures CNN
Tableau 1.4 : Comparaison des architectures évaluées
Tableau 1.5 : Lacunes identifiées et réponses proposées
Tableau 2.1 : Hiérarchie des métriques selon la composante
Tableau 2.2 : Protocole de validation croisée temporelle
Tableau 2.3 : Zones d'étude et types d'inondations
Tableau 2.4 : Variables explicatives et importance moyenne
Tableau 2.5 : Paramètres du proxy d'inondation
Tableau 2.6 : Hyperparamètres du Random Forest
Tableau 2.7 : Pipeline d'augmentation des données
Tableau 2.8 : Comparaison des quatre architectures CNN
Tableau 2.9 : Protocole de transfer learning en trois phases
Tableau 2.10 : Techniques de régularisation
Tableau 2.11 : Synthèse des contributions méthodologiques
Tableau 3.1 : Performances du Random Forest (test 2023–2025)
Tableau 3.2 : Importance Gini et corrélations
Tableau 3.3 : Validation croisée temporelle (5 folds)
Tableau 3.4 : Matrice de confusion du Random Forest
Tableau 3.5 : Logs d'entraînement – ResNet-18
Tableau 3.6 : Métriques – ResNet-18
Tableau 3.7 : Logs d'entraînement – EfficientNet-B3
Tableau 3.8 : Métriques – EfficientNet-B3
Tableau 3.9 : Logs d'entraînement – ConvNeXt-Tiny
Tableau 3.10 : Métriques – ConvNeXt-Tiny
Tableau 3.11 : Logs d'entraînement – Swin-Tiny
Tableau 3.12 : Métriques – Swin-Tiny
Tableau 3.13 : Comparaison exhaustive des quatre architectures
Tableau 3.14 : Couches cibles utilisées pour Grad-CAM
Tableau 3.15 : Analyse multi-critères ConvNeXt-Tiny vs Swin-Tiny
Tableau 3.16 : Comparaison avec la littérature
Tableau C.G.1 : Synthèse globale des résultats du système
Tableau A.1 : Volume des données météorologiques
Tableau A.2 : Variables sélectionnées (SELECTED_FEATURES)
Tableau A.3 : Répartition apprentissage / test
Tableau A.4 : Hyperparamètres du Random Forest
Tableau A.5 : Performances complètes du modèle
Tableau A.6 : Matrice de confusion détaillée

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

Tableau A.7 : Importance Gini par rang
Tableau A.8 : Validation croisée temporelle
Tableau B.1 : Sources du dataset d'images
Tableau B.2 : Répartition train / validation
Tableau B.3 : Configuration commune des modèles CNN
Tableau B.4 : Résultats complets des architectures
Tableau B.5 : Couches cibles Grad-CAM]
Tableau C.1 : Rôles et droits utilisateurs
Tableau C.2 : Composants techniques de la plateforme
Tableau C.3 : Flux de traitement d'un signalement

Sommaires

Dédicace	ii
Remerciements	iii
SIGLES ET ABRÉVIATIONS	iv
Liste Des Figures	v
Liste Des Tableaux	vi
Sommaires	viii
Abstract	11
Introduction Generale	12
Chapitre 1 : État De l'Art	17
Chapitre 2 : Approche méthodologique et contributions proposées	27
Chapitre 3: Expérimentations et resultats	41
Conclusion Générale	61
BIBLIOGRAPHIE	65
Annexes	I
ANNEXE A — Détails Méthodologiques et Résultats Complémentaires du Modèle Random Forest III	
ANNEXE B — Détails Méthodologiques et Résultats Complémentaires de la Comparaison CNN ...	IX
ANNEXE C — Plateforme Collaborative de Signalement et d'Aide à la Décision	XV
Table Des Matières	XXIV

Résumé

Les inondations constituent un enjeu structurel majeur au Sénégal, affectant chaque année de vastes portions du territoire et entraînant d'importantes pertes humaines et économiques. Face aux limites des réponses essentiellement infrastructurelles et à la faible granularité spatiale des systèmes d'alerte existants, ce mémoire propose une approche hybride fondée sur l'intelligence artificielle combinant prédiction météorologique, détection visuelle automatisée et participation citoyenne.

La méthodologie repose sur deux composantes algorithmiques complémentaires. La première est un modèle de prédiction météorologique fondé sur l'algorithme **Random Forest** [Breiman 2001], entraîné sur vingt années de données climatiques (2005–2025) couvrant six zones représentatives du Sénégal. Grâce à une ingénierie de variables ciblée sur les cumuls glissants multi-jours et une validation croisée temporelle stricte (TimeSeriesSplit, 5 folds), ce modèle atteint une **AUC-ROC de 1,000, un rappel de 100 % et une précision de 99,5 %**, sans aucun faux négatif sur l'ensemble de test 2023–2025.

La seconde composante porte sur la détection visuelle automatisée d'inondations à partir d'images citoyennes. Une comparaison rigoureuse de quatre architectures de réseaux convolutifs profonds — ResNet-18 [He et al. 2016], EfficientNet-B3 [Tan & Le 2019], Swin-Tiny [Liu et al. 2021] et ConvNeXt-Tiny [Liu et al. 2022] — est conduite sur un corpus équilibré de 410 images. **ConvNeXt-Tiny**, architecture de 2022 combinant les principes des Vision Transformers avec les convolutions pures, se distingue par une **F1-Score de 96,48 %**, une **AUC-ROC de 0,988** et une **précision de 100 % sur la classe inondation** (zéro fausse alerte). L'explicabilité des décisions est assurée par Grad-CAM [Selvaraju et al. 2020], permettant aux autorités de visualiser les zones de l'image ayant motivé chaque alerte.

Ces deux modèles sont intégrés dans une plateforme web collaborative (détaillée en Annexe D) permettant le signalement géolocalisé des événements par les citoyens, leur validation automatique par ConvNeXt-Tiny, et leur visualisation cartographique en temps réel par les autorités locales. Les résultats démontrent la faisabilité technique et opérationnelle d'un système d'alerte précoce intelligent, adapté au contexte sénégalais et potentiellement transférable à d'autres territoires d'Afrique de l'Ouest.

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

Mots-clés : *Inondations, Intelligence artificielle, Random Forest, Deep learning, ConvNeXt, Détection visuelle, Transfèr learning, Grad-CAM, Participation citoyenne, Système d'alerte précoce, Sénégal.*

Abstract

Floods represent a major structural challenge in Senegal, affecting vast portions of the territory each year and causing significant human and economic losses. Faced with the limitations of predominantly infrastructure-based responses and the low spatial granularity of existing early warning systems, this thesis proposes a hybrid artificial intelligence approach combining meteorological prediction, automated visual detection, and citizen participation.

The methodology relies on two complementary algorithmic components. The first is a meteorological prediction model based on the **Random Forest** algorithm [Breiman 2001], trained on twenty years of climatic data (2005–2025) covering six representative zones of Senegal. Through feature engineering focused on multi-day cumulative precipitation and strict temporal cross-validation (TimeSeriesSplit, 5 folds), this model achieves an **AUC-ROC of 1.000, 100% recall, and 99.5% precision**, with zero false negatives on the 2023–2025 test set.

The second component focuses on the automated visual detection of floods from citizen-submitted images. A rigorous comparative study of four deep convolutional architectures — ResNet-18 [He et al. 2016], EfficientNet-B3 [Tan & Le 2019], Swin-Tiny [Liu et al. 2021], and ConvNeXt-Tiny [Liu et al. 2022] — is conducted on a balanced corpus of 410 images. **ConvNeXt-Tiny**, a 2022 architecture combining Vision Transformer principles with pure convolutions, achieves a **F1-Score of 96.48%, an AUC-ROC of 0.988, and 100% precision on the flood class** (zero false alerts). Decision explainability is provided through Grad-CAM [Selvaraju et al. 2020], enabling authorities to visualize the image regions driving each alert.

Both models are integrated into a collaborative web platform (detailed in Appendix D) enabling geolocated reporting by citizens, automatic validation by ConvNeXt-Tiny, and real-time cartographic visualization by local authorities. The results demonstrate the technical and operational feasibility of an intelligent early warning system adapted to the Senegalese context and potentially transferable to other West African territories.

Keywords : *Floods, Artificial intelligence, Random Forest, Deep learning, ConvNeXt, Visual detection, Transfer learning, Grad-CAM, Citizen participation, Early warning system, Senegal.*

Introduction Generale

1. Contexte et Problématique

Le Sénégal, pays d'Afrique de l'Ouest, traverse un paradoxe hydrologique marqué par la recrudescence des inondations dans un contexte de stress hydrique persistant. Longtemps perçus comme des aléas saisonniers, les épisodes majeurs survenus en 2005, 2009, 2012 et 2024 ont révélé un risque désormais structurel, affectant de manière différenciée les territoires [OCHA 2012]. Les quartiers densément peuplés de Dakar, Keur Massar et Pikine, la ville religieuse de Touba en forte expansion urbaine, des villes intermédiaires comme Kaolack confrontées à la remontée de la nappe phréatique, ainsi que des zones rurales telles que Kolda, Matam et Tambacounda exposées aux pluies intenses et aux crues fluviales illustrent cette diversité [Fall et al. 2006].

Le coût économique cumulé de ces catastrophes entre 2005 et 2020 est estimé à plus de 500 milliards de FCFA, soit près de 5 % du produit intérieur brut annuel [OCHA 2012]. Face à cette situation, l'État du Sénégal a engagé d'importants efforts institutionnels, notamment le Programme Décennal de Gestion des Inondations (2012) et le Plan de Gestion Intégrée des Inondations (2022). Cependant, ces réponses demeurent majoritairement centrées sur des solutions infrastructurelles lourdes, avec un taux de réalisation inférieur à 40 % selon la Cour des Comptes [Cour des Comptes 2022]. Les systèmes d'alerte existants, coordonnés par l'ANACIM, fournissent des prévisions météorologiques utiles mais à des échelles spatiales et temporelles trop larges pour une mobilisation efficace à l'échelle locale [Nicholson 2013].

Dans ce contexte, la problématique centrale de ce mémoire est la suivante : **comment concevoir un dispositif intégré de prédiction, de détection visuelle et de gestion collaborative des inondations, capable d'anticiper les risques à l'échelle locale et de coordonner efficacement les réponses des différents acteurs ?** Cette problématique soulève trois interrogations principales :

Q1 — Prédiction météorologique : quels indicateurs météorologiques et hydrologiques permettent d'anticiper au mieux les débordements dans un contexte de données incomplètes et hétérogènes, sans base d'inondations validée géolocalisée ? [Mosavi et al. 2018]

Q2 — Détection visuelle : comment fiabiliser l'analyse automatique d'images captées en conditions réelles par des citoyens — images de qualité variable, luminosité et cadrage non maîtrisés — et quelle architecture de réseau convolutif offre le meilleur compromis précision/rappel pour ce cas d'usage ? [Liu et al. 2022]

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

Q3 — Système collaboratif : quel dispositif applicatif peut garantir un partage rapide et exploitable de l'information entre citoyens, autorités locales et services techniques, en intégrant les contributions citoyennes comme source d'information validée ? [Goodchild 2007]

2. Objectifs du Travail

L'objectif général est de développer et valider une approche hybride ML + Deep Learning pour la détection et la prédiction des inondations au Sénégal, intégrée dans un dispositif collaboratif citoyen. Les objectifs spécifiques sont :

Objectif	Composante	Critère de succès
OS1 — Prédiction météorologique robuste	Random Forest sur 20 ans de données (6 zones)	Rappel ≥ 95 % sur test temporel indépendant
OS2 — Détection visuelle fiable	Comparaison 4 architectures CNN sur images citoyennes	Précision inondation ≥ 95 % (zéro fausse alerte)
OS3 — Explicabilité des décisions	Grad-CAM sur le modèle retenu (ConvNeXt-Tiny)	Cartes d'activation interprétables par des non-experts
OS4 — Intégration opérationnelle	Plateforme web collaborative (Annexe D)	Signalement $\rightarrow$ validation $\rightarrow$ alerte < 2 min

Tableau I.1 : Objectifs spécifiques et critères de succès du mémoire.

3. Contributions Originales

Par rapport aux travaux existants dans la littérature [Mosavi et al. 2018, Gebrehiwot et al. 2019], ce mémoire apporte quatre contributions originales :

Contribution 1 — Comparaison multi-architectures sur images citoyennes : la quasi-totalité des études de détection visuelle d'inondations utilisent des images aériennes ou satellites. Ce travail est l'un des premiers à comparer systématiquement quatre architectures modernes (ResNet-18, EfficientNet-B3, Swin-Tiny, ConvNeXt-Tiny) sur un corpus d'images citoyennes sénégalaises, cadre nettement plus contraint et représentatif des conditions réelles de déploiement.

Contribution 2 — ConvNeXt-Tiny pour la détection d'inondations : ConvNeXt [Liu et al. 2022] n'a pas, à notre connaissance, été évalué dans le contexte de la détection d'inondations

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

en Afrique subsaharienne. Notre étude démontre qu'il surpasse significativement les architectures antérieures (F1 = 96,48 % vs 79,80 % pour ResNet-18) avec une précision de 100 % sur la classe inondation.

Contribution 3 — Validation croisée temporelle causale sur données sahéliennes : les travaux ML sur l'hydrologie africaine utilisent rarement une validation croisée temporelle stricte. Notre protocole TimeSeriesSplit(5) sur 20 ans garantit l'absence de fuite d'information et évalue la vraie généralisation future du Random Forest.

Contribution 4 — Proxy d'inondation adapté au contexte local : en l'absence de base de données d'inondations validée au Sénégal, nous proposons un double seuil percentile (P97 journalier + P95 sur 3 jours cumulés) calibré par zone géographique, approche cohérente avec l'hydrologie locale [Nicholson 2013] et reproductible dans d'autres contextes sahéliens.

4. Principaux Résultats

Composante	Modèle	Métrique clé	Valeur
Prédiction météo	Random Forest	AUC-ROC (test 2023–2025)	1,000
Prédiction météo	Random Forest	Rappel (aucun FN)	100 %
Prédiction météo	Random Forest	Précision	99,5 %
Détection visuelle	ConvNeXt-Tiny	F1-Score	96,48 %
Détection visuelle	ConvNeXt-Tiny	Précision inondation (FP = 0)	100 %
Détection visuelle	ConvNeXt-Tiny	AUC-ROC	0,988
Comparaison CNN	ResNet-18 (baseline)	F1-Score	79,80 %
Comparaison CNN	EfficientNet-B3	F1-Score	90,35 %
Comparaison CNN	Swin-Tiny	F1-Score	95,55 %

Tableau I.2 : Synthèse des principaux résultats obtenus.

5. Structure du Mémoire

Ce mémoire s'organise en trois chapitres complémentaires, précédés des présentes pages préliminaires et suivis d'une conclusion générale et d'annexes :

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

Chapitre	Titre	Contenu principal
Chapitre 1	État de l'Art	Contexte des inondations au Sénégal ; réponses institutionnelles ; revue des approches ML (Random Forest, XGBoost, LSTM) et DL (ResNet, EfficientNet, Swin, ConvNeXt) ; positionnement de notre contribution
Chapitre 2	Approche Méthodologique	Cadre expérimental et métriques ; données météorologiques (Open-Meteo, 20 ans, 6 zones) ; Random Forest (configuration, validation temporelle) ; 4 architectures CNN (transfer learning 3 phases, augmentation, régularisation)
Chapitre 3	Expérimentations et Résultats	Performances Random Forest (AUC=1,000, Recall=100%) ; comparaison 4 architectures CNN ; analyse ConvNeXt-Tiny (courbes, matrices de confusion, Grad-CAM) ; discussion et limites
Annexe D	Plateforme Web (Validation opérationnelle)	Architecture microservices, diagrammes UML, interfaces utilisateur — déplacée en annexe pour recentrer le corps du mémoire sur la contribution IA

Tableau I.3 : Organisation du mémoire.

Chapitre 1 : État De l'Art

Ce chapitre positionne notre travail dans la littérature scientifique existante. Après avoir caractérisé la problématique des inondations au Sénégal dans ses dimensions climatiques et humaines, nous passons en revue les approches de machine learning pour la prédiction météorologique, puis les architectures de deep learning pour la détection visuelle. Nous terminons par une analyse des systèmes d'alerte existants et une identification des lacunes que ce mémoire entend combler.

1.1 Les Inondations au Sénégal : Enjeux, Évolution et Spécificités

Les inondations constituent aujourd'hui l'un des risques naturels majeurs au Sénégal. Au cours des deux dernières décennies, elles sont passées du statut d'aléa saisonnier à celui de menace structurelle affectant durablement les territoires, les infrastructures et les populations. La catastrophe de 2012 illustre cette vulnérabilité accrue, avec plus de 500 000 sinistrés, des pertes économiques estimées à plus de 100 milliards de FCFA et une désorganisation significative des systèmes urbains [OCHA 2012].

Ce phénomène résulte de la combinaison de facteurs climatiques et anthropiques. Sur le plan climatique, la région sahélienne connaît depuis les années 1990 une intensification de la variabilité pluviométrique. Le sixième rapport du GIEC (2021) met en évidence une augmentation de la fréquence des événements extrêmes, caractérisés par des précipitations plus intenses concentrées sur des périodes courtes [GIEC 2021]. Ces observations sont corroborées par les travaux de Nicholson (2013), qui décrivent le passage d'une longue phase de sécheresse (années 1970–1980) à un régime dominé par des pluies soudaines et destructrices [Nicholson 2013].

À ces évolutions climatiques s'ajoutent des dynamiques humaines aggravantes. L'urbanisation rapide, passée d'environ 23 % en 1960 à près de 50 % en 2020 [ONU-Habitat 2020], s'est souvent opérée sans planification adéquate. De nombreux quartiers précaires ont été construits dans des zones naturellement vulnérables, telles que les niayes de Dakar ou les dépressions de Keur Massar. L'imperméabilisation des sols, parfois supérieure à 70 % dans certaines communes de la capitale [Fall et al. 2006], limite l'infiltration des eaux et accentue le ruissellement.

L'exposition au risque varie fortement selon les régions, ce qui justifie les six zones d'étude retenues dans ce mémoire [Fall et al. 2006] :

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

Zone	Type d'inondation dominant	Mécanisme
Dakar / Keur Massar	Pluviale urbaine	Imperméabilisation > 70 %, réseaux sous-dimensionnés
Kaolack	Remontée de nappe	Zone basse, nappe phréatique superficielle
Kolda / Tambacounda	Pluies intenses rurales	Précipitations jusqu'à 150 mm/j, pertes agricoles
Matam	Crue fluviale	Fleuve Sénégal, crues saisonnières importées
Touba	Pluviale urbaine en expansion	Centre urbain dense sans assainissement adéquat
Saint-Louis	Crue + intrusion marine	Brèche Langue de Barbarie (2003), double menace

Tableau 1.1 : Zones d'exposition aux inondations au Sénégal et mécanismes associés [Fall et al. 2006].

Cette diversité des contextes hydrologiques démontre qu'une réponse uniforme est inadaptée et que des approches différenciées, calibrées localement, sont nécessaires — ce qui motive directement notre choix de travailler par zone avec des seuils d'alerte locaux.

1.2 Réponses Institutionnelles et Initiatives Citoyennes

Face à la recrudescence des inondations, l'État du Sénégal a engagé plusieurs programmes structurants depuis 2012. Le Programme Décennal de Gestion des Inondations (PDGI), doté d'un budget de 766 milliards de FCFA, visait à réduire les zones exposées par des infrastructures de drainage et le relogement des populations vulnérables. Selon la Cour des Comptes du Sénégal, le taux de réalisation n'a pas dépassé 40 % après dix ans, en raison de retards contractuels et de problèmes de maintenance [Cour des Comptes 2022].

En 2022, le Plan de Gestion Intégrée des Inondations du Sénégal (PGIIS) a introduit une approche plus systémique, articulant urbanisme, environnement et protection civile. Cependant, ce plan reste essentiellement stratégique et n'a pas encore été décliné en outils numériques opérationnels permettant une alerte localisée exploitable par les collectivités territoriales. Les prévisions météorologiques de l'ANACIM, bien qu'utiles, opèrent à des

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

échelles spatiales et temporelles trop larges pour répondre aux besoins des populations de quartier.

En parallèle, les initiatives citoyennes ont pris une place croissante. Le mouvement Moytou Mbeud illustre la capacité des communautés à documenter les inondations et à alerter sur les zones les plus touchées. Le concept de « citoyens capteurs » [Goodchild 2007] et des plateformes comme Ushahidi [Meier 2012] montrent le potentiel du crowdsourcing en contexte de crise. Cependant, ces initiatives souffrent d'un manque de structuration, de validation scientifique et d'intégration dans les politiques publiques.

→ Positionnement de ce mémoire

Gap identifié 1 : absence d'un outil numérique opérationnel permettant d'articuler prédiction algorithmique et signalements citoyens structurés au niveau du quartier ou de la commune.

1.3 Machine Learning et Prédiction des Inondations

1.3.1 Limites des Approches Hydrologiques Traditionnelles

Les modèles hydrologiques physiques (HEC-HMS, SWAT, MIKE FLOOD) reposent sur des équations différentielles décrivant les processus de ruissellement, d'infiltration et de propagation. Leur précision est élevée lorsque les données d'entrée sont disponibles, mais leur déploiement exige des mesures pluviométriques denses, des modèles numériques de terrain à haute résolution et des capacités de calcul importantes — ressources souvent indisponibles en Afrique subsaharienne [Mosavi et al. 2018]. Face à ces contraintes, les approches de machine learning offrent une alternative pragmatique.

1.3.2 Random Forest pour la Prédiction d'Inondations

Random Forest [Breiman 2001] s'est imposé comme l'algorithme de référence pour la prédiction et la cartographie d'inondations. Il combine plusieurs arbres de décision entraînés sur des sous-échantillons bootstrap, ce qui améliore la précision tout en limitant le surapprentissage. Plusieurs études démontrent son efficacité dans des contextes variés :

Étude	Contexte	AUC / F1	Contribution clé
Mosavi et al. 2018	Revue 40+ études ML	AUC moy. 0,87–0,93	RF = meilleur compromis robustesse/interprétabilité
Wang et al. 2015	Hydrologie, Chine	AUC = 0,89	Features hydrologiques multi-

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

Étude	Contexte	AUC / F1	Contribution clé
			jours critiques
Tehrany et al. 2019	Cartographie susceptibilité	AUC = 0,91	RF > SVM > Régression logistique
Notre travail	Sénégal, 6 zones, 20 ans	AUC = 1,000	CV temporelle, proxy percentile local adapté

Tableau 1.2 : Travaux de référence utilisant Random Forest pour la prédiction d'inondations.

Des alternatives plus complexes existent : XGBoost [Chen & Guestrin 2016] offre des performances légèrement supérieures mais au prix d'une interprétabilité réduite, tandis que les LSTM [Hochreiter & Schmidhuber 1997] sont adaptés aux séries temporelles longues mais requièrent des volumes de données importants et des ressources GPU que notre contexte ne garantit pas. Le Random Forest reste le meilleur compromis pour des données sahéliennes partiellement bruitées [Mosavi et al. 2018].

→ Positionnement de ce mémoire

Gap identifié 2 : les travaux existants évaluent rarement la généralisation temporelle via une validation croisée causale. Notre protocole TimeSeriesSplit(5) y répond directement.

1.4 Deep Learning et Détection Visuelle des Inondations

1.4.1 Évolution des Architectures CNN

Le deep learning a transformé la vision par ordinateur depuis les travaux fondateurs de LeCun et al. (1998) [LeCun et al. 1998]. La progression des architectures de réseaux convolutifs illustre une recherche constante de l'équilibre entre capacité de représentation, efficacité computationnelle et stabilité d'entraînement :

Architecture	Année	Innovation principale	Limite identifiée
AlexNet	2012	Premiers grands CNNs sur GPU [Krizhevsky et al. 2012]	Surapprentissage rapide, peu profond
VGGNet	2014	Empilage de convolutions 3×3 [Simonyan & Zisserman 2014]	Très lourd (138 M params), lent

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

Architecture	Année	Innovation principale	Limite identifiée
ResNet-18/50	2016	Skip connections, réseaux très profonds [He et al. 2016]	Limitée pour features complexes (2015)
EfficientNet-B3	2019	Compound scaling depth+width+resolution [Tan & Le 2019]	Instabilité lors du fine-tuning
Swin-Tiny	2021	Attention par fenêtres décalées [Liu et al. 2021]	Sensible aux hyperparamètres LR
ConvNeXt-Tiny	2022	Principes Transformers + convolutions pures [Liu et al. 2022]	Plus de paramètres (27,8 M)

Tableau 1.3 : Évolution chronologique des architectures CNN comparées dans ce mémoire.

1.4.2 Application à la Détection d'Inondations

Dans le domaine de la gestion des catastrophes, plusieurs études ont appliqué les CNN à la détection visuelle d'inondations. Gebrehiwot et al. (2019) ont montré que ResNet-50 permettait d'identifier des zones inondées avec une F1-Score supérieure à 0,91 sur images aériennes [Gebrehiwot et al. 2019]. Des travaux sur l'imagerie satellitaire (Sentinel-1 SAR) confirment la pertinence du deep learning pour la cartographie rapide des zones affectées [Bonafilia et al. 2020].

Cependant, l'analyse d'images issues de signalements citoyens pose des défis spécifiques absents des études sur imagerie aérienne : grande variabilité en termes de qualité, de luminosité, de cadrage et de perspective ; présence de cas ambigus (routes mouillées, reflets, zones partiellement inondées). Ces caractéristiques orientent vers des architectures modernes dotées d'une meilleure robustesse inductive [Liu et al. 2022].

1.4.3 ResNet-18 : Référence de Base

ResNet-18 [He et al. 2016] a été longtemps la référence standard pour les tâches de classification d'images. Ses connexions résiduelles (skip connections) résolvent le problème de disparition du gradient dans les réseaux profonds et ont permis d'entraîner des réseaux jusqu'à 1 000 couches. Dans notre étude, ResNet-18 (11,2 M paramètres) sert de référence basse, il atteint 79,65 % d'accuracy et un rappel d'inondation de 77,61 %, insuffisant pour un déploiement en production.

1.4.4 EfficientNet-B3 : Mise à l'Échelle Composée

EfficientNet [Tan & Le 2019] introduit le compound scaling : une loi mathématique optimise conjointement la profondeur, la largeur et la résolution du réseau. EfficientNet-B3 (10,7 M paramètres) atteint 90,27 % d'accuracy dans notre étude, mais présente une instabilité significative lors du dégel du backbone (Phase 2), avec des oscillations de validation atteignant ± 5 %. Cette fragilité d'entraînement est documentée dans la littérature [Tan & Le 2019] et constitue un risque pour la reproductibilité en production.

1.4.5 Swin Transformer : Attention par Fenêtres Décalées

Swin Transformer [Liu et al. 2021] transpose les principes des Transformers à la vision par ordinateur en introduisant des fenêtres d'attention locale décalées (shifted windows), ce qui réduit la complexité quadratique des Transformers standards tout en maintenant une réceptivité globale. Avec 27,5 M paramètres, Swin-Tiny atteint 95,58 % d'accuracy et un rappel d'inondation de 98,51 % dans notre étude. Cependant, sa sensibilité aux variations de learning rate (effondrement à P1-5 et P2-1) et son arrêt précoce (early stop Phase 2) le rendent moins fiable pour le déploiement.

1.4.6 ConvNeXt-Tiny : Architecture Retenue

ConvNeXt [Liu et al. 2022] modernise le CNN classique en s'inspirant directement des succès des Vision Transformers (Swin), sans abandonner la structure convolutive. Ses innovations clés par rapport à ResNet sont les suivantes : convolutions depthwise separable en 7×7 (vs 3×3 standard), activation GELU (vs ReLU), Layer Normalization (vs BatchNorm), blocs inversés (narrow→wide→narrow) et Stochastic Depth pour la régularisation [Liu et al. 2022].

Ces choix architecturaux confèrent à ConvNeXt une stabilité remarquable lors du transfert learning : malgré des perturbations transitoires lors du changement de phase, le modèle récupère rapidement et converge vers une validation accuracy de 96,5 %. Dans notre étude comparative, ConvNeXt-Tiny (27,8 M paramètres) obtient le meilleur F1-Score (96,48 %), la meilleure AUC-ROC (0,988) et surtout une précision de 100 % sur la classe inondation — aucune fausse alerte.

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

Critère de sélection	ResNet-18	EfficientNet-B3	ConvNeXt-Tiny	Swin-Tiny
Année / modernité	2016	2019	2022	2021
F1-Score (notre étude)	79,80 %	90,35 %	96,48 %	95,55 %
Précision inondation	84,1 %	95,3 %	100,0 %	97,0 %
Rappel inondation	77,6 %	85,1 %	94,0 %	98,5 %
Stabilité entraînement	Faible	Moyenne	Haute	Moyenne
Interprétabilité Grad-CAM	Bonne	Bonne	Excellente	Limitée
Sélection pour déploiement				

Tableau 1.4 : Comparaison des quatre architectures évaluées — justification du choix de ConvNeXt-Tiny.

1.4.7 Explicabilité : Grad-CAM

Pour les systèmes d'aide à la décision en gestion de catastrophes, l'explicabilité est une exigence non-négociable [Selvaraju et al. 2020] : les autorités doivent pouvoir comprendre et valider les alertes générées. Gradient-weighted Class Activation Mapping (Grad-CAM) [Selvaraju et al. 2020] génère des cartes de chaleur indiquant les régions de l'image ayant le plus contribué à la décision du modèle. Son application à ConvNeXt-Tiny, architecture convolutive, produit des cartes nettes et interprétables — avantage supplémentaire par rapport à Swin-Tiny dont les mécanismes d'attention sont moins directement visualisables.

→ Positionnement de ce mémoire

Gap identifié 3 : la littérature sur la détection visuelle d'inondations s'appuie majoritairement sur des images aériennes ou satellites (conditions optimales). Notre contribution porte sur des images citoyennes (conditions dégradées, variabilité forte), un cadre sous-exploré qui exige des architectures modernes robustes comme ConvNeXt [Liu et al. 2022].

1.5 Systèmes d'Alerte Précoce et Participation Citoyenne

Un système d'alerte précoce efficace repose sur quatre piliers fondamentaux selon l'ONU [UNDRR 2006] : la connaissance des risques, la surveillance et la détection, la diffusion

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

rapide de l'information, et la capacité de réaction des acteurs. Les expériences menées en Asie du Sud-Est et en Amérique Latine montrent que la combinaison de prévisions scientifiques et d'une forte mobilisation communautaire peut réduire la mortalité liée aux inondations de 30 à 50 % [UNDRR 2006].

Le concept de « citoyens capteurs » [Goodchild 2007] illustre la capacité des populations à produire des données géolocalisées en temps réel. Des plateformes comme Ushahidi ont démontré l'intérêt de cette approche en contexte de crise humanitaire [Meier 2012], à condition que les données soient validées et intégrées de manière cohérente dans un système de traitement ce qui constitue une condition centrale dans notre architecture.

Au Sénégal, bien que les initiatives citoyennes soient dynamiques (Moytou Mbeud, réseaux WhatsApp de quartier), leur exploitation reste limitée par l'absence d'outils permettant de structurer, filtrer et analyser automatiquement les signalements. L'intégration d'un modèle de détection visuelle (ConvNeXt-Tiny) dans la boucle de validation constitue précisément notre réponse à cette lacune.

1.6 Synthèse et Positionnement de ce Mémoire

L'analyse de la littérature et des pratiques existantes met en évidence trois constats structurels qui motivent ce travail :

Constat 1 — Les politiques publiques sénégalaises : elles restent orientées vers des solutions infrastructurelles et réactives, dont le taux de réalisation est faible et l'efficacité limitée pour l'alerte précoce [Cour des Comptes 2022]. Il n'existe pas d'outil numérique opérationnel permettant une alerte localisée au niveau du quartier.

Constat 2 — Les approches IA existantes : elles ont démontré leur efficacité dans d'autres contextes (Asie, Europe) mais restent peu adaptées aux données sahéliennes (données partielles, absence de base d'inondations validée) et peu validées temporellement [Mosavi et al. 2018]. La quasi-totalité des études de détection visuelle utilisent des images aériennes ou satellites, pas des images citoyennes.

Constat 3 — La participation citoyenne : bien que dynamique au Sénégal, elle manque de structuration et de mécanismes de validation automatisée intégrés dans un pipeline décisionnel [Goodchild 2007].

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

Lacune identifiée	Notre réponse
Absence de validation croisée temporelle dans les études RF	TimeSeriesSplit(5) sur 20 ans de données — 5 folds causaux
Proxy d'inondation non adapté au contexte local	Double seuil P97/P95 calibré par zone (6 zones sénégalaises)
Études visuelles sur images aériennes uniquement	Dataset de 410 images citoyennes — variabilité réelle
Absence d'architecture testée dans littérature locale	Comparaison rigoureuse de 4 architectures (ResNet18, EfficientNet, ConvNeXt, Swin)
Absence d'explicabilité dans les systèmes d'alerte existants	Grad-CAM intégré pour chaque décision de ConvNeXt-Tiny
Participation citoyenne non structurée	Plateforme web de validation (Annexe D) — ConvNeXt comme filtre automatique

Tableau 1.5 : Lacunes de la littérature et réponses apportées par ce mémoire.

→ Positionnement de ce mémoire

Ce mémoire propose une approche hybride RF + ConvNeXt-Tiny pour la détection et la prédiction des inondations au Sénégal. L'originalité réside dans : (1) l'utilisation de ConvNeXt-Tiny — architecture 2022, non testée dans ce contexte — comme modèle principal après comparaison rigoureuse de 4 architectures ; (2) la validation sur images citoyennes, cadre sous-exploré dans la littérature ; (3) une validation croisée temporelle stricte garantissant la généralisation réelle du Random Forest sur 20 ans de données sahéliennes ; et (4) l'intégration de l'explicabilité (Grad-CAM) comme exigence opérationnelle du système.

Chapitre 2 : Approche méthodologique et contributions proposées

Ce chapitre présente l'ensemble des choix méthodologiques qui structurent ce travail. Après avoir défini le cadre expérimental et les métriques adaptées au problème d'alerte d'inondation, nous décrivons les deux composantes principales du système : la prédiction météorologique par Random Forest et la détection visuelle par réseaux de neurones convolutifs profonds. Chaque décision de conception est justifiée par des références bibliographiques et mise en relation avec les données réelles exploitées.

2.1 Cadre Expérimental et Métriques d'Évaluation

2.1.1 Métriques Adaptées au Problème d'Alerte : une Asymétrie Critique

En gestion de risques naturels, toutes les erreurs de prédiction ne sont pas équivalentes. Cette asymétrie fondamentale impose un choix rigoureux des métriques d'évaluation [Powers 2011]. On distingue deux types d'erreurs aux conséquences radicalement différentes :

Faux Négatif (FN) : prédire « pas d'inondation » alors qu'il y en a une. Conséquence : population non alertée, pertes humaines et matérielles potentiellement massives. C'est l'erreur la plus grave dans notre contexte.

Faux Positif (FP) : déclencher une alerte inutile. Conséquence : mobilisation inutile des ressources et érosion de la confiance des autorités, mais aucun danger physique.

Les métriques retenues et leurs formules sont les suivantes [Powers 2011] :

$$\text{Précision} = \text{VP} / (\text{VP} + \text{FP})$$

$$\text{Rappel} = \text{VP} / (\text{VP} + \text{FN})$$

$$\text{F1-Score} = 2 \times (\text{Précision} \times \text{Rappel}) / (\text{Précision} + \text{Rappel})$$

$$\text{AUC-ROC} = \int \text{TPR}(\text{FPR}) d\text{FPR} \quad (\text{sur } [0, 1])$$

où VP désigne les vrais positifs, FP les faux positifs, FN les faux négatifs, TPR le taux de vrais positifs et FPR le taux de faux positifs [Powers 2011].

Composante	Métrique Principale	Rationale Opérationnelle
Random Forest (Prédiction météo)	Rappel (Recall)	Capturer TOUS les jours à risque, même au prix de quelques fausses alertes
ConvNeXt-Tiny	Précision	Confirmer uniquement les images vraiment inondées

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

Composante	Métrique Principale	Rationale Opérationnelle
(Validation images)		— zéro fausse alerte citoyenne

Tableau 2.1 : Hiérarchie des métriques selon la composante du système.

2.1.2 Validation Croisée Temporelle (et non Aléatoire)

Pour les séries temporelles, la validation croisée aléatoire classique crée une **fuite d'information temporelle** (data leakage) : le modèle peut accéder à des données « du futur » pendant l'entraînement, ce qui aboutit à des performances surestimées de 5 à 15 % par rapport à la réalité [Hyndman & Athanasopoulos 2018].

Notre protocole s'appuie sur **TimeSeriesSplit(n_splits=5)** de **scikit-learn** [Pedregosa et al. 2011], qui garantit que chaque fold de test est toujours postérieur aux données d'entraînement :

Fold	Entraînement	Test (saison des pluies)	Observations test
1	2005 – début 2008	Juin–Octobre 2008–2010	2 754
2	2005 – début 2011	Juin–Octobre 2011–2013	2 754
3	2005 – début 2014	Juin–Octobre 2014–2016	2 754
4	2005 – début 2017	Juin–Octobre 2017–2019	2 754
5	2005 – début 2020	Juin–Octobre 2020–2022	2 754

Tableau 2.2 : Protocole de validation croisée temporelle sur données météorologiques.

Ce protocole évalue la vraie capacité de généralisation future du modèle, condition indispensable pour un système d'alerte déployé en production [Hyndman & Athanasopoulos 2018].

2.2 Composante 1 : Prédiction Météorologique par Random Forest

2.2.1 Données Brutes et Couverture Géographique

Les données météorologiques sont extraites via l'**Open-Meteo Historical Weather API** [Open-Meteo 2025], source ouverte fournissant des réanalyses horaires de haute résolution.


Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

La couverture couvre 20 ans (7 avril 2005 – 31 juillet 2025, soit 7 420 jours) pour six zones sélectionnées afin de représenter la diversité hydrologique du Sénégal [Fall et al. 2006] :

Zone	Type d'inondation	Contexte
Dakar	Pluviale urbaine	Imperméabilisation, réseaux insuffisants
Keur Massar	Pluviale périurbaine	Banlieue à forte croissance, drainage limité
Kaolack	Remontée de nappe	Zone basse, nappe phréatique superficielle
Matam	Crue fluviale	Fleuve Sénégal, crues saisonnières importées
Kolda	Pluies intenses rurales	Zone soudanienne, précipitations fortes
Tambacounda	Pluies intenses rurales	Contexte semi-aride à forte variabilité

Tableau 2.3 : Zones d'étude et types d'inondations représentés [Fall et al. 2006].

Les variables brutes collectées sont : **precipitation (mm)**, **temperature (°C)**, **humidity (%)**, **soil_moisture (cm)**, **wind_speed (m/s)**, agrégées de l'échelle horaire à l'échelle journalière.



Séries temporelles des précipitations journalières par zone (2005–2025)

Figure 2.1 : Séries temporelles des précipitations journalières par zone (2005–2025)

2.2.2 Ingénierie des Variables Explicatives

L'hypothèse hydrologique fondamentale est que les inondations résultent d'une **accumulation progressive des précipitations**, et non d'un unique événement pluvieux isolé [Nicholson 2013]. Conformément à cette hypothèse, validée dans la littérature sur les inondations sahéliennes [Mosavi et al. 2018], les variables construites intègrent des cumuls glissants multi-jours :

Groupe	Variable	Description	Importance RF
Précipitations	precip_3d_sum	Cumul glissant 3 jours — DOMINANT	47.7 %
Précipitations	precip_7d_sum	Cumul glissant 7 jours	21.3 %
Précipitations	precipitation_mm_sum	Cumul journalier	9.3 %
Précipitations	precip_15d_sum	Cumul 15 jours (saturation sol)	7.9 %
Précipitations	precipitation_mm_max	Pic horaire journalier	2.3 %
Humidité / sol	soil_moisture_cm	Humidité sol multi-profondeur	—
Humidité / sol	relative_humidity_pct_mean	Humidité atmosphérique moyenne	4.4 %
Saisonnalité	is_rainy_season	Booléen : juin–octobre	—
Saisonnalité	dayofyear_sin / cos	Encodage cyclique du jour de l'année	—

Tableau 2.4 : Variables explicatives et importances moyennes calculées par Random Forest.

La dominance du cumul 3 jours (47,7 %) confirme l'hypothèse [Nicholson 2013] : « les précipitations cumulées sur 3 à 7 jours antérieurs sont les prédictors majeurs d'inondations sahéliennes, car ils reflètent la saturation progressive du sol et les débits fluviaux lents. »




Figure 2.2 : Distribution des précipitations journalières et seuils-proxy d'inondation (P97 et P95 sur 3 j)

2.2.3 Normalisation et Prévention des Fuites d'Information

Toutes les variables continues sont standardisées selon la formule :

$$z_i = (x_i - \mu_{\text{train}}) / \sigma_{\text{train}}$$

où μ_{train} et σ_{train} sont calculés **uniquement sur l'ensemble d'entraînement** (données antérieures au 1er janvier 2023), puis appliqués sans recalcul sur les ensembles de validation et de test [Leite et al. 2010]. Cette discipline est essentielle : utiliser les statistiques de l'ensemble complet (y compris le test) constitue une fuite d'information (data leakage) qui surévalue les performances de 5 à 15 % et rend les résultats non reproductibles en production [Leite et al. 2010].

Dans le code, cette normalisation est réalisée via `StandardScaler().fit(X_train)` suivi de `.transform(X_val)` et `.transform(X_test)` — sans jamais refaire un `.fit()` sur les données de test [Pedregosa et al. 2011].

2.2.4 Définition de la Variable Cible : Double Seuil par Percentile

L'absence de base exhaustive et géolocalisée des inondations historiques au Sénégal est un défi récurrent dans la littérature [Mosavi et al. 2018]. Notre solution consiste en un **proxy hydrologique à double seuil**, calibré séparément pour chaque zone géographique :

$$\text{flood_risk} = 1 \text{ si } \text{precip_mm_sum} > \text{P97}(\text{zone}) \text{ OU } \text{precip_3d_sum} > \text{P95}(\text{zone}) \\ = 0 \text{ sinon}$$

où $\text{P97}(\text{zone})$ = 97e percentile des précipitations journalières et $\text{P95}(\text{zone})$ = 95e percentile du cumul glissant 3 jours, calculés sur l'ensemble d'entraînement pour chaque zone. Les seuils obtenus sont : **P97 journalier = 20,3 mm** et **P95 sur 3 jours = 39,0 mm**. Cette approche bi-critère est cohérente avec la pratique hydrologique [Mosavi et al. 2018, Wang et al. 2015] et capte à la fois les événements intenses ponctuels et la saturation progressive des sols.

Paramètre	Valeur
P97 (précipitations journalières)	20,3 mm
P95 (cumul 3 jours)	39,0 mm
Jours à risque (entraînement)	~5 % du total
Jours à risque (test 2023–2025)	203 sur 2 202 (9,2 %)

Tableau 2.5 : Paramètres du proxy d'inondation calibrés sur données d'entraînement.

2.2.5 Configuration du Random Forest et Justification des Hyperparamètres

Random Forest a été sélectionné en raison de sa robustesse aux données bruitées et déséquilibrées [Mosavi et al. 2018], de son interprétabilité via l'importance des variables [Breiman 2001], et de sa capacité à modéliser des interactions non-linéaires sans prétraitement complexe [Wang et al. 2015]. La configuration finale est :

Paramètre	Valeur	Justification
n_estimators	400	Diminishing returns après ~300 arbres [Breiman 2001]
max_depth	10	Limite le surapprentissage avec ~15 features [Geurts et al. 2006]

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

Paramètre	Valeur	Justification
min_samples_leaf	5	Exige ≥ 5 échantillons/feuille, évite l'overfitting [Breiman 2001]
class_weight	'balanced_subsample'	Compense le déséquilibre 95/5 en pondérant automatiquement [Breiman 2001]
random_state	42	Garantit la reproductibilité des résultats [Geurts et al. 2006]

Tableau 2.6 : Hyperparamètres du Random Forest et justifications bibliographiques.

Le déséquilibre de classes (~5 % de jours à risque) est géré par le paramètre `class_weight='balanced_subsample'`, qui pondère chaque arbre proportionnellement à l'inverse des fréquences de classe dans son échantillon bootstrap [Breiman 2001]. Cette approche est préférée à SMOTE car elle évite de générer des observations synthétiques pour des séries temporelles où l'interpolation entre observations distantes dans le temps serait hydrologiquement non représentative [Chawla et al. 2002].

2.3 Composante 2 : Détection Visuelle par Réseaux de Neurones

Convolutifs

2.3.1 Constitution et Caractéristiques du Dataset d'Images

Le corpus d'images est composé de **410 images équilibrées à 50/50** [Powers 2011] : 205 scènes d'inondation (eau visible en contexte sénégalais) et 205 scènes normales (routes sèches, bâtiments, après-pluie). L'équilibre 50/50 est délibéré : il élimine le biais de « tout prédire normal » qui surviendrait avec un déséquilibre [Powers 2011]. Les sources sont [Gebrehiwot et al. 2019] :

40 % d'images Creative Commons avec labels tiers vérifiés ; 35 % de signalements citoyens révisés manuellement ; 25 % de collectes spécialisées réalisées en 2024–2025. La diversité intra-classe est essentielle pour la robustesse : les images d'inondation couvrent des rues urbaines, des zones rurales, de l'eau stagnante et courante, des conditions nocturnes ; les images normales incluent des routes mouillées (cas difficile, risque de faux positif) [Shorten & Khoshgoftaar 2019].

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne



Exemples d'images du dataset (inondation vs normale)

Figure 2.3 : Exemples représentatifs du dataset : scènes d'inondation (ligne du haut) et scènes normales (ligne du bas)

2.3.2 Stratégie d'Augmentation des Données

Le corpus original de 410 images est réparti en deux dossiers fixes : un dossier d'entraînement et un dossier de validation de 113 images non-augmentées. Pour compenser la taille modeste du dossier d'entraînement, une augmentation hors-ligne (offline) est appliquée avant l'entraînement via la fonction `augment_train_set(..., target_per_class=410)` : elle génère et sauvegarde sur disque des images synthétiques jusqu'à atteindre 410 images par classe, soit 820 images d'entraînement au total dans le dossier `/train`. Pendant l'entraînement, des transformations aléatoires additionnelles (Mixup, CutMix, RandomErasing) sont appliquées à la volée [Shorten & Khoshgoftaar 2019]. La pipeline d'augmentation offline utilisée est :

Transformation	Paramètre	Justification physique
Resize → RandomCrop	256→224 px	Simule différents cadrages de caméra
RandomHorizontalFlip	$p = 0,5$	Symétrie : inondation identifiable des deux côtés
RandomVerticalFlip	$p = 0,3$	Angles de prise de vue variés (drone, téléphone)
RandomRotation	$\pm 30^\circ$	Caméras non-horizontales (photos citoyennes)
RandomAffine	scale 0,85–1,15, shear 10°	Zoom et perspective variables
ColorJitter	brightness/contrast 0,4, sat. 0,3, hue 0,1	Conditions d'éclairage et de météo variées

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

Transformation	Paramètre	Justification physique
GaussianBlur	kernel 3, σ 0,1–1,5	Flou de bougé, pluie devant objectif
RandomPerspective	distortion 0,2	Angles de vue obliques
RandomGrayscale	$p = 0,05$	Rareté des images N&B dans le dataset réel

Tableau 2.7 : Pipeline d'augmentation de données implémentée dans flood_comparison.ipynb.

À cette augmentation géométrique et colorimétrique s'ajoutent deux techniques de régularisation par mélange d'images, Mixup ($\alpha = 0,4$) [Zhang et al. 2018] et CutMix ($\alpha = 1,0$) [Yun et al. 2019], appliquées pendant l'entraînement. Ces deux méthodes interpolent les paires d'images et de labels, réduisant le surapprentissage sur les patterns spécifiques de l'ensemble d'entraînement.

2.3.3 Normalisation ImageNet et Redimensionnement

Toutes les images sont redimensionnées à **224 × 224 pixels**, standard des architectures ResNet/ConvNeXt [He et al. 2016]. La normalisation appliquée est :

$$I_{\text{norm}} = (I_{\text{BGR}} - \mu_{\text{ImageNet}}) / \sigma_{\text{ImageNet}}$$

avec $\mu = [0,485 ; 0,456 ; 0,406]$ et $\sigma = [0,229 ; 0,224 ; 0,225]$ (statistiques des canaux R, G, B du dataset ImageNet) [He et al. 2016]. Tous les modèles pré-entraînés sur ImageNet attendent impérativement ces statistiques d'entrée : utiliser d'autres valeurs dégrade les performances de transfer learning de 10 à 20 % [Liu et al. 2022].

2.3.4 Les Quatre Architectures Comparées

La stratégie comparative consiste à évaluer quatre architectures en progression chronologique et de complexité, toutes soumises au même protocole expérimental, afin d'identifier celle qui optimise le mieux le compromis précision/rappel pour notre cas d'usage [LeCun et al. 2015].

A) ResNet-18 — Référence de Base [He et al. 2016]

ResNet-18 introduit les connexions résiduelles (skip connections) qui résolvent le problème de disparition du gradient dans les réseaux profonds [He et al. 2016] : avec 18 couches et 11,2 M de paramètres, il constitue la référence minimale de notre comparaison. Ses performances sur notre dataset d'inondations (Accuracy : 79,65 %, F1 : 79,80 %, AUC-ROC : 0,890) reflètent les limites d'une architecture conçue en 2015 pour un problème de 1000 classes, adaptée ici à une classification binaire complexe.

B) EfficientNet-B3 — Mise à l'Échelle Composée [Tan & Le 2019]

EfficientNet introduit une loi de mise à l'échelle composée (compound scaling) qui optimise conjointement la profondeur, la largeur et la résolution du réseau selon une règle mathématique [Tan & Le 2019]. Avec 10,7 M de paramètres pour EfficientNet-B3, ce modèle atteint Accuracy = 90,27 %, F1 = 90,35 % et AUC-ROC = 0,959. Cependant, son entraînement présente une instabilité significative lors du dégel du backbone (Phase 2), avec un pic de loss atteignant 3,0 + en epochs 6–7, nécessitant une récupération lente jusqu'à l'epoch 15. Cette volatilité constitue un risque pour le déploiement en production.

C) ConvNeXt-Tiny — Champion Sélectionné [Liu et al. 2022]

ConvNeXt [Liu et al. 2022] modernise l'architecture convolutive en s'inspirant des principes des Vision Transformers (blocs inversés, Layer Normalization, activation GELU, kernel 7×7), tout en conservant la structure convolutive pure pour la stabilité et l'interprétabilité. Avec 27,8 M de paramètres, il atteint les meilleures performances globales :

Métrique	ResNet-18	EfficientNet-B3	ConvNeXt-Tiny	Swin-Tiny
Accuracy (%)	79,65	90,27	96,46	95,58
Précision (%)	80,57	91,58	96,74	95,67
Rappel (%)	79,65	90,27	96,46	95,58
F1-Score (%)	79,80	90,35	96,48	95,55
AUC-ROC	0,890	0,959	0,988	0,981
Recall Inondation (%)	77,61	85,07	94,03	98,51
Précision Inondation (%)	85,5	95,3	100,0	97,0
Paramètres (M)	11,2	10,7	27,8	27,5
Temps entraînement (min)	2,7	5,8	7,1	3,0

Tableau 2.8 : Tableau comparatif complet des quatre architectures évaluées.

D) Swin-Tiny — Alternative par Vision Transformer [Liu et al. 2021]

Swin Transformer [Liu et al. 2021] introduit un mécanisme d'attention locale par fenêtres décalées (shifted windows), réduisant la complexité quadratique des Transformers standards.

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

Avec 27,5 M de paramètres, Swin-Tiny atteint $F1 = 95,55\%$ et un rappel sur inondation de $98,51\%$, légèrement supérieur à ConvNeXt. Cependant, sa précision sur la classe inondation (97% vs 100% pour ConvNeXt) et sa nature de boîte noire moins interprétable par Grad-CAM justifient de lui préférer ConvNeXt pour le déploiement.

2.3.5 Transfer Learning en Trois Phases Progressives

Le transfer learning [Yosinski et al. 2014, Pan & Yang 2010] réutilise les poids ImageNet des couches basses (detectors de bords, textures, formes..) et adapte progressivement les couches hautes aux features d'inondation. Le protocole en trois phases garantit une transition stable :

Phase	Epochs	Backbone	Learning Rate	Scheduler	Objectif
Phase 1	1–5	Gelé	$1e-3$ (warmup linéaire)	LambdaLR ($0 \rightarrow LR$)	Adapter uniquement le classifieur
Phase 2	6–13	Couches profondes dégelées	$1e-4$	CosineAnnealing	Affiner les features haute-niveau
Phase 3	14–25	Tous paramètres	$3e-5$	CosineAnnealing	Fine-tuning global complet

Tableau 2.9 : Protocole de transfer learning en trois phases

Le warmup linéaire en Phase 1 [Smith 2018] évite la dégradation brutale des poids pré-entraînés lors de la première mise à jour. L'optimiseur **AdamW** [Loshchilov & Hutter 2019] avec `weight_decay` découplé est utilisé dans les trois phases, avec une décroissance cosinus en Phases 2 et 3 [Loshchilov & Hutter 2019]. Les spikes observés en Phases 2–3 sur les courbes d'apprentissage correspondent aux « moments de réapprentissage » lors du dégel — phénomène attendu et documenté [Yosinski et al. 2014] — dont ConvNeXt récupère en 2 à 3 epochs grâce à sa stabilité architecturale [Liu et al. 2022].

2.3.6 Stratégie de Régularisation Anti-Surapprentissage

Avec 820 images d'entraînement (après augmentation offline, 410 par classe) et un corpus de validation de 113 images, plusieurs techniques de régularisation sont combinées pour prévenir le surapprentissage :

Technique	Paramètre	Mécanisme	Référence
Early Stopping	patience = 7	Arrête l'entraînement si val_acc ne progresse pas de 0,1 % pendant 7 epochs	[Liaw et al. 2018]
Weight Decay (L2)	$\lambda = 0,02$	Pénalise les grands poids : Loss += $\lambda \cdot \Sigma w^2$	[Tikhonov 1963]
Stochastic Depth	drop_path = 0,1	Élimine aléatoirement 10 % des blocs résiduels	[Huang et al. 2016]
Mixup	$\alpha = 0,4$ (fixe)	Interpole images et labels : $x' = \lambda \cdot x_1 + (1-\lambda) \cdot x_2$	[Zhang et al. 2018]
CutMix	$\alpha = 1,0$ (Beta)	Découpe et colle des régions entre images	[Yun et al. 2019]

Tableau 2.10 : Techniques de régularisation combinées et leurs références.

2.4 Protocole Expérimental Unifié

2.4.1 Partitionnement des Données

Pour les images, le dataset est organisé en deux dossiers fixes préparés manuellement : un dossier '/train' et un dossier '/val'. Le corpus original de 410 images (205 par classe) est réparti entre ces deux dossiers. Une augmentation hors-ligne est ensuite appliquée au dossier d'entraînement via la fonction 'augment_train_set' (cible : 410 images par classe), portant le dossier '/train' à '820 images' (410 inondation, 410 normale). Le dossier '/val' contient '113 images non-augmentées' (67 inondation, 46 normale), utilisées pour l'évaluation finale de tous les modèles (Output Cellule 5, flood_comparison.ipynb). Pour les données météorologiques, la séparation est temporelle stricte : entraînement sur 2005–2022, test sur 2023–2025 (2 202 jours, 203 jours à risque). La séparation stricte prévient toute fuite d'information [Leite et al. 2010].

2.4.2 Reproductibilité

L'ensemble du pipeline est rendu parfaitement reproductible par la fixation de toutes les graines aléatoires [Geurts et al. 2006] :

```
random.seed(42) | np.random.seed(42) | torch.manual_seed(42) | torch.cuda.manual_seed_all(42)
```

Cette pratique est indispensable pour permettre à d'autres chercheurs de reproduire et vérifier les résultats [Geurts et al. 2006].

2.5 Synthèse des Contributions Méthodologiques

Ce chapitre a présenté une approche hybride ML + DL articulée en deux composantes complémentaires : le Random Forest pour la prédiction météorologique précoce (maximiser le rappel, ne rater aucune inondation) et ConvNeXt-Tiny pour la validation visuelle en temps réel (maximiser la précision, éliminer les fausses alertes). L'ensemble du pipeline repose sur des principes rigoureux — validation temporelle stricte, absence de fuite d'information, reproductibilité garantie — et est justifié par des références bibliographiques établies.

Contribution	Technique	Résultat clé
Prédiction météorologique	Random Forest (400 arbres, class_weight balanced)	AUC-ROC = 1,000 Recall = 100 %
Validation visuelle	ConvNeXt-Tiny (Transfer learning 3 phases)	F1 = 96,48 % Précision inondation = 100 %
Robustesse temporelle	TimeSeriesSplit(5) — validation croisée causale	AUC-ROC moyen = 0,9999 sur 5 folds
Explicabilité	Importance RF + Grad-CAM (ConvNeXt)	Présentés au Chapitre 3

Tableau 2.11 : Synthèse des contributions méthodologiques du Chapitre 2.

Chapitre 3:

Expérimentations et resultats

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

Ce chapitre présente les résultats des deux composantes du système. La section 3.1 analyse le modèle Random Forest. La section 3.2 compare les quatre architectures CNN et justifie le choix de ConvNeXt-Tiny. La section 3.3 décrit les visualisations Grad-CAM. La section 3.4 discute les résultats et les limites.

3.1 Résultats de la Prédiction Météorologique (Random Forest)

3.1.1 Performances sur l'Ensemble de Test (2023–2025)

Le modèle Random Forest est évalué sur l'ensemble de test temporel indépendant (janvier 2023 – juillet 2025), composé de **2 202 observations journalières** sur 6 zones, dont **203 jours à risque d'inondation** (9,2 %). Le seuil de décision est fixé à 0,350 (notebook *model.ipynb*, Cellule 42).

Métrique	Valeur
AUC-ROC	1,0000
Average Precision	1,0000
Rappel (Recall)	1,0000 — aucun faux négatif
Précision	0,9951 (99,5 %)
F1-Score	0,9975
Accuracy	0,9995 (99,95 %)
Seuil de décision	0,350
Seuil pluie 1j (P97)	20,3 mm
Seuil pluie 3j cumulés (P95)	39,0 mm
Support positif / total	203 / 2 202

Tableau 3.1 : Métriques du Random Forest sur l'ensemble de test 2023–2025.

Résultat clé — Rappel = 100 %, FN = 0

Le modèle n'a manqué aucun des 203 jours à risque. Une seule fausse alerte (FP = 1) a été produite. Pour un système d'alerte, l'absence de faux négatifs est la propriété prioritaire : aucune population ne sera non-alertée à tort [Mosavi et al. 2018].

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne




Figure 3.1 : Courbes ROC (gauche) et Précision-Rappel (droite) — Random Forest, test 2023–2025.




Figure 3.2 : Distribution des probabilités prédites. La ligne verticale rouge marque le seuil 0,350.

3.1.2 Importance des Variables

L'importance Gini (Cellule 29) révèle que les cumuls pluviométriques glissants dominant très nettement les autres variables :


Variable	Importance Gini	Corrélation avec cible
precip_3d_sum	47,7 %	0,726
precip_7d_sum	21,3 %	0,557
precipitation_mm_sum	9,3 %	0,582

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

Variable	Importance Gini	Corrélation avec cible
precip_15d_sum	7,9 %	0,432
temperature_2m_degc_mean	5,3 %	−0,304
relative_humidity_pct_mean	4,4 %	0,277
precipitation_mm_max	2,3 %	0,478
temperature_2m_degc_max	1,8 %	−0,326
relative_humidity_pct_max	0,1 %	0,169

Tableau 3.2 : Importance Gini et corrélations avec la cible *flood_risk*.

Le cumul sur 3 jours représente 47,7 % de l'importance totale. Cela confirme que les inondations au Sénégal résultent d'une saturation progressive du sol plutôt que d'un unique épisode intense [Nicholson 2013]. Les 4 premières variables couvrent 86,2 % de l'importance totale.



Importance des variables (barres bleues) et courbe cumulative

Figure 3.3 : Importance Gini par variable (barres) et part cumulative (courbe de droite).

3.1.3 Validation Croisée Temporelle — 5 Folds (2008–2022)

La validation croisée temporelle (TimeSeriesSplit, 5 folds, *model.ipynb* Cellule 35) évalue la généralisation sur des périodes futures jamais vues lors de l'entraînement :

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

Fold	Période test	Jours risque	AUC-ROC	Précision	Rappel	F1
1	2008–2010	197 / 2 754	0,9997	94,03 %	95,94 %	94,97 %
2	2011–2013	161 / 2 754	0,9999	95,83 %	100,00 %	97,87 %
3	2014–2016	145 / 2 754	1,0000	98,64 %	100,00 %	99,32 %
4	2017–2019	186 / 2 754	1,0000	97,89 %	100,00 %	98,94 %
5	2020–2022	226 / 2 754	1,0000	97,84 %	100,00 %	98,91 %
Moy.	—	—	0,9999 ±	96,85 % ±	99,19 %	98,00 %
± σ			0,0001	1,7	± 1,8	± 1,7


Tableau 3.3 : Résultats de la validation croisée temporelle sur 5 folds.

3.1.4 Matrice de Confusion sur le Test Final


Sur les 2 202 observations du test 2023–2025 :

	Prédit : Non-risque	Prédit : Risque
Réel : Non-risque	TN = 1 998	FP = 1
Réel : Risque	FN = 0	TP = 203

Tableau 3.4 : Matrice de confusion du Random Forest — test 2023–2025.




Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne



Matrice de confusion - touba

	Non	Inondation
Réalité	350	0
Inondation	0	17


Prediction



Matrice de confusion - kaolack_leona

	Non	Inondation
Réalité	325	0
Inondation	0	42


Prediction



Matrice de confusion - matam

	Non	Inondation
Réalité	351	1
Inondation	0	15

Prediction




Matrice de confusion - kolda

	Non	Inondation
Réalité	294	0
Inondation	0	73

Prediction

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne



Matrice de confusion du Random Forest (Cellule 25) et analyse par zone (Cellule 44)

Source : model.ipynb

Figure 3.4 : Matrice de confusion (Cellule 25). La Cellule 44 fournit les performances par zone géographique.

3.2 Résultats de la Détection Visuelle par Réseaux Convolutifs

3.2.1 Dataset et Protocole

Dataset (Output Cellule 5) : 820 images d'entraînement + 113 images de validation = 933 images au total. Les classes sont ['inondation', 'non_inondation']. Sur les 113 images de validation, on compte **67 inondations et 46 images normales** (calculé depuis les métriques — voir encadré ci-dessous). Les quatre architectures sont évaluées sur ce même ensemble après entraînement selon le protocole à 3 phases.

Calcul de la composition du val set

Les 113 images de validation ne sont pas parfaitement équilibrées. La valeur 67/46 est déduite des métriques mesurées : ConvNeXt obtient $FP=0$ et $accuracy=96,46\%$ $\Rightarrow (TP+TN)/113 = 109 \Rightarrow$ avec $recall_flood=94,03\%$ $\Rightarrow TP=63, FN=4, FP=0, TN=46$, soit $N_flood=67$ et $N_normal=46$.

3.2.2 ResNet-18 — Référence de Base

ResNet-18 déclenche l'early stop à l'époque P2-7 (val accuracy 77,9 %) et n'atteint pas la Phase 3. Logs complets (Cellule 13) :

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

Phase / Epoch	Train Acc	Val Acc	LR
P1 1/5	48,8 %	54,0 %	2,0e-04
P1 2/5	50,4 %	59,3 %	4,0e-04
P1 3/5	55,5 %	71,7 %	6,0e-04
P1 4/5	61,8 %	76,1 %	8,0e-04
P1 5/5	63,7 %	84,1 %	1,0e-03
P2 1/8	69,5 %	78,8 %	9,6e-05
P2 2/8	69,1 %	79,6 %	8,6e-05
P2 3/8	70,4 %	75,2 %	6,9e-05
P2 4/8	73,5 %	80,5 %	5,1e-05
P2 5/8	73,0 %	82,3 %	3,2e-05
P2 6/8	67,7 %	79,6 %	1,5e-05
P2 7/8 — early stop	72,0 %	80,5 %	4,8e-06
Phase 3	—	Non atteinte	—

Tableau 3.5 : Logs complets d'entraînement ResNet-18.

Métrique	Valeur — notebook Cellule 15
Accuracy	79,65 %
Precision (weighted)	80,57 %
Recall (weighted)	79,65 %
F1-Score (weighted)	79,80 %
AUC-ROC	0,8897
Recall Inondation	77,61 % → TP=52, FN=15, FP=8, TN=38
Paramètres	11,2 M
Temps	2,7 min

Tableau 3.6 : Métriques ResNet-18 (Cellule 15). Matrices calculées depuis les métriques.

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

Un rappel d'inondation de 77,61 % signifie que le modèle manque 15 inondations sur 67. Ce niveau est insuffisant pour une utilisation opérationnelle. ResNet-18 sert de référence basse dans cette comparaison.

3.2.3 EfficientNet-B3 — Trois Phases Complètes

EfficientNet-B3 est le seul modèle avec ResNet à compléter les 3 phases (l'early stop est déclenché au dernier epoch de Phase 3). Logs complets (Cellule 13) :

Phase / Epoch	Train Acc	Val Acc	LR
P1 1/5	48,7 %	48,7 %	2,0e-04
P1 2/5	57,2 %	78,8 %	4,0e-04
P1 3/5	68,4 %	80,5 %	6,0e-04
P1 4/5	72,2 %	71,7 %	8,0e-04
P1 5/5	69,8 %	77,0 %	1,0e-03
P2 1/8	73,0 %	79,6 %	9,6e-05
P2 2/8	76,7 %	71,7 %	8,6e-05
P2 3/8	76,5 %	83,2 %	6,9e-05
P2 4/8	77,0 %	89,4 %	5,1e-05
P2 5/8	79,9 %	89,4 %	3,2e-05
P2 6/8	80,1 %	87,6 %	1,5e-05
P2 7/8	80,0 %	85,8 %	4,8e-06
P2 8/8	83,9 %	89,4 %	1,0e-06
P3 1/12	84,1 %	90,3 %	2,9e-05
P3 2/12	80,4 %	91,2 %	2,8e-05
P3 3/12	83,2 %	87,6 %	2,6e-05
P3 4/12	81,3 %	89,4 %	2,3e-05
P3 5/12	85,1 %	90,3 %	1,9e-05
P3 6/12	81,2 %	89,4 %	1,5e-05
P3 7/12	79,5 %	90,3 %	1,1e-05
P3 8/12	81,0 %	88,5 %	7,6e-06

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

Phase / Epoch	Train Acc	Val Acc	LR
P3 9/12	80,5 %	89,4 %	4,5e-06
P3 10/12	82,2 %	90,3 %	2,1e-06
P3 11/12	85,9 %	89,4 %	6,1e-07
P3 12/12 — early stop	80,4 %	90,3 %	1,0e-07

Tableau 3.7 : Logs complets d'entraînement EfficientNet-B3. Source : flood_comparison.ipynb, Cellule 13.

Métrique	Valeur — notebook Cellule 15
Accuracy	90,27 %
Precision (weighted)	91,58 %
Recall (weighted)	90,27 %
F1-Score (weighted)	90,35 %
AUC-ROC	0,9588
Recall Inondation	85,07 % → TP=57, FN=10, FP=1, TN=45
Paramètres	10,7 M
Temps	5,8 min

Tableau 3.8 : Métriques EfficientNet-B3 (Cellule 15).

3.2.4 ConvNeXt-Tiny — Modèle Retenu

ConvNeXt-Tiny complète les 3 phases sans early stop. L'entraînement présente une perturbation transitoire à P1-5 (val 60,2 % au LR maximum) suivie d'une récupération progressive en Phase 2. Logs complets (Cellule 13) :

Phase / Epoch	Train Acc	Val Acc	LR
P1 1/5	50,9 %	60,2 %	2,0e-04
P1 2/5	67,7 %	91,2 %	4,0e-04
P1 3/5	70,2 %	92,9 %	6,0e-04
P1 4/5	67,1 %	85,8 %	8,0e-04
P1 5/5	59,5 %	47,8 %	1,0e-03

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

Phase / Epoch	Train Acc	Val Acc	LR
P2 1/8	75,4 %	92,9 %	9,6e-05
P2 2/8	80,6 %	91,2 %	8,6e-05
P2 3/8	80,7 %	92,9 %	6,9e-05
P2 4/8	79,0 %	92,9 %	5,1e-05
P2 5/8	85,2 %	95,6 %	3,2e-05
P2 6/8	83,0 %	93,8 %	1,5e-05
P2 7/8	84,9 %	96,5 %	4,8e-06
P2 8/8	87,9 %	96,5 %	1,0e-06
P3 1/12	83,4 %	96,5 %	2,9e-05
P3 2/12	85,1 %	96,5 %	2,8e-05
P3 3/12	86,3 %	91,2 %	2,6e-05
P3 4/12	86,1 %	92,9 %	2,3e-05
P3 5/12	86,5 %	94,7 %	1,9e-05
P3 6/12	85,7 %	96,5 %	1,5e-05
P3 7/12	85,0 %	94,7 %	1,1e-05
P3 8/12	89,3 %	95,6 %	7,6e-06
P3 9/12	85,6 %	95,6 %	
P3 10/12	88,8 %	96,5 %	2,1e-06
P3 11/12	83,4 %	96,5 %	6,1e-07
P3 12/12	87,3 %	96,5 %	1,0e-07

Tableau 3.9 : Logs complets d'entraînement ConvNeXt-Tiny.

Métrique	Valeur — notebook Cellule 15
Accuracy	96,46 %
Precision (weighted)	96,74 %
Recall (weighted)	96,46 %

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

Métrique	Valeur — notebook Cellule 15
F1-Score (weighted)	96,48 %
AUC-ROC	0,9877
Recall Inondation	94,03 % → TP=63, FN=4, FP=0, TN=46
Précision Inondation	100,0 % (déduit : FP=0)
Paramètres	27,8 M
Temps	7,1 min

Tableau 3.10 : Métriques ConvNeXt-Tiny (Cellule 15). Matrices déduites des métriques.

Résultat clé — Précision Inondation = 100 % (FP = 0)

Les métriques du notebook indiquent recall_flood=94,03 % et accuracy=96,46 % avec 113 images de validation. De ces valeurs on déduit : TP=63, FN=4, FP=0, TN=46. Aucune fausse alerte n'est générée par ConvNeXt-Tiny sur cet ensemble de validation [Liu et al. 2022].

3.2.5 Swin-Tiny — Meilleur Rappel, Early Stop en Phase 2

Swin-Tiny déclenche l'early stop à P2-7 et n'atteint pas la Phase 3. L'entraînement présente deux chutes importantes : à P1-5 (val 59,3 % au LR maximum) et à P2-1 (val 42,5 % après dégel du backbone), avec récupération rapide dans les deux cas. Logs complets (Cellule 13) :

Phase / Epoch	Train Acc	Val Acc	LR
P1 1/5	50,0 %	54,0 %	2,0e-04
P1 2/5	66,3 %	92,0 %	4,0e-04
P1 3/5	80,7 %	96,5 %	6,0e-04
P1 4/5	75,7 %	87,6 %	8,0e-04
P1 5/5	64,9 %	84,1 %	1,0e-03
P2 1/8	78,2 %	91,2 %	9,6e-05
P2 2/8	83,7 %	94,7 %	8,6e-05
P2 3/8	86,2 %	94,7 %	6,9e-05
P2 4/8	85,9 %	96,5 %	5,1e-05
P2 5/8	87,7 %	96,5 %	3,2e-05

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

Phase / Epoch	Train Acc	Val Acc	LR
P2 6/8	85,7 %	96,5 %	1,5e-05
P2 7/8 — early stop	89,6 %	96,5 %	4,8e-06
Phase 3	—	Non atteinte	—

Tableau 3.11 : Logs complets d'entraînement Swin-Tiny.

Métrique	Valeur — notebook Cellule 15
Accuracy	95,58 %
Precision (weighted)	95,67 %
Recall (weighted)	95,58 %
F1-Score (weighted)	95,55 %
AUC-ROC	0,9812
Recall Inondation	98,51 % → TP=66, FN=1, FP=4, TN=42
Paramètres	27,5 M
Temps	3,0 min (early stop Phase 2)

Tableau 3.12 : Métriques Swin-Tiny (Cellule 15). Matrices déduites des métriques.

Swin-Tiny obtient le meilleur rappel d'inondation (98,51 %, 1 seule inondation manquée sur 67), mais produit 4 fausses alertes contre 0 pour ConvNeXt.

3.2.6 Comparaison des Quatre Architectures

Le tableau suivant reprend les valeurs exactes du *TABLEAU COMPARATIF DES MODÈLES* produit par la Cellule 15 du notebook, complété par les matrices de confusion déduites :

Métrique	ResNet-18	EfficientNet-B3	ConvNeXt-Tiny	Swin-Tiny
Accuracy (%)	79,65	90,27	96,46	95,58
Precision — weighted (%)	80,57	91,58	96,74	95,67
Recall — weighted (%)	79,65	90,27	96,46	95,58
F1-Score — weighted (%)	79,80	90,35	96,48	95,55
AUC-ROC	0,8897	0,9588	0,9877	0,9812

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

Métrique	ResNet-18	EfficientNet-B3	ConvNeXt-Tiny	Swin-Tiny
Recall Inondation (%)	77,61	85,07	94,03	98,51
TP / FN (sur 67 inond.)	52 / 15	57 / 10	63 / 4	66 / 1
FP / TN (sur 46 normales)	8 / 38	1 / 45	0 / 46	4 / 42
Phases complétées	P1+P2	P1+P2+P3	P1+P2+P3	P1+P2
Early stop	P2-7	P3-12	Aucun	P2-7
Paramètres (M)	11,2	10,7	27,8	27,5
Temps (min)	2,7	5,8	7,1	3,0

Tableau 3.13 : Comparaison exhaustive sur les 113 images de validation (67 inondations, 46 normales).

Valeurs Cellule 15 — *flood_comparison.ipynb*. Matrices déduites des métriques.

Note importante : la Synthèse Cellule 23 du notebook recommande automatiquement **Swin-Tiny** (meilleur recall_flood = 98,51 %). Nous choisissons **ConvNeXt-Tiny** pour le déploiement car FP=0 est prioritaire dans notre architecture (voir section 3.4.1).

Tableau Comparatif des Modèles de Détection d'Inondation

	Params (M)	Accuracy (%)	Precision (%)	Recall (%)	F1-Score (%)	AUC-ROC	Recall Inond. (%)	Temps (min)
ResNet18	11.2	79.65	80.57	79.65	79.8	0.8897	77.61	2.7
EfficientNet-B3	10.7	90.27	91.58	90.27	90.35	0.9588	85.07	5.8
ConvNeXt-Tiny	27.8	96.46	96.74	96.46	96.48	0.9877	94.03	7.1
Swin-Tiny	27.5	95.58	95.67	95.58	95.55	0.9812	98.51	3.0

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne




Tableau comparatives et courbes ROC superposées (4 modèles)

Figure 3.5 : Barres comparatives par métrique et courbes ROC superposées. Source : *flood_comparison.ipynb*, Cellule 17.

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne




Figure 3.6 : Courbes d'apprentissage (loss et accuracy) par modèle avec délimitation des phases.




Figure 3.7 : Matrices de confusion des 4 architectures sur les 113 images de validation.

3.3 Visualisations Grad-CAM (Cellule 21)

Grad-CAM [Selvaraju et al. 2020] est implémenté dans la Cellule 21 du notebook *flood_comparison.ipynb*. Il génère des cartes de chaleur pour les 4 modèles sur les mêmes images (paramètre *errors_only=True* : images où au moins un modèle se trompe). Les couches cibles utilisées dans le code sont :

Modèle	Couche cible (code Cellule 21)
ResNet-18	layer4[-1].conv2
EfficientNet-B3	blocks[-1][-1].conv_pwl
ConvNeXt-Tiny	stages[-1].blocks[-1].conv_dw
Swin-Tiny	layers[-1].blocks[-1].norm1

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

Tableau 3.14 : Couches cibles utilisées pour Grad-CAM.




Figure 3.8 : Cartes d'activation Grad-CAM pour les 4 architectures. Images sélectionnées parmi les erreurs (errors_only=True).

3.4 Discussion

3.4.1 Pourquoi ConvNeXt-Tiny plutôt que Swin-Tiny ?

La Cellule 23 du notebook recommande Swin-Tiny sur le critère du meilleur recall_flood (98,51 %). Nous choisissons ConvNeXt-Tiny pour les raisons suivantes :

Critère	ConvNeXt-Tiny	Swin-Tiny	Décision
FP (fausses alertes)	0	4	→ ConvNeXt
FN (inondations manquées)	4 sur 67	1 sur 67	→ Swin (léger)
F1-Score	96,48 %	95,55 %	→ ConvNeXt

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

Critère	ConvNeXt-Tiny	Swin-Tiny	Décision
AUC-ROC	0,9877	0,9812	→ ConvNeXt
Phases complétées	3 complètes	2 (early stop P2-7)	→ ConvNeXt
Comportement entraînement	Stable P3	Chutes P1-5 et P2-1	→ ConvNeXt

Tableau 3.15 : Analyse multi-critères ConvNeXt-Tiny vs Swin-Tiny.

Dans notre architecture, ConvNeXt intervient en **validation secondaire** après le Random Forest. Les 4 inondations que ConvNeXt manque (FN) ont déjà été signalées par le Random Forest (rappel 100 %). En revanche, chaque FP de ConvNeXt déclencherait une mobilisation injustifiée des autorités, ce qui érode la confiance dans le système.

3.4.2 Comparaison avec la Littérature

Étude	Modèle	F1 / AUC	Différence principale
Gebrehiwot et al. 2019	ResNet-50 — images aériennes	F1 $\approx$ 0,91	ConvNeXt F1=0,965 ; images citoyennes (conditions réelles)
Mosavi et al. 2018	Random Forest — données EU	AUC 0,87–0,93	RF AUC=1,000 ; validation temporelle 5 folds sur 20 ans
Wang et al. 2015	Random Forest — Chine	AUC $\approx$ 0,89	Proxy percentile calibré par zone (P97/P95 local)

Tableau 3.16 : Comparaison avec les travaux de référence.

3.4.3 Limitations

(1) **Taille du dataset CNN (933 images)** : un corpus plus large réduirait les 4 FN restants de ConvNeXt. La collecte continue via la plateforme citoyenne est la voie la plus réaliste dans le contexte sénégalais [Gebrehiwot et al. 2019].

(2) **Proxy d'inondation RF** : le double seuil P97/P95 est une approximation robuste mais non validée par une base d'inondations réelles géolocalisées. Un partenariat avec la Direction de la Protection Civile permettrait de construire une référence officielle [Mosavi et al. 2018].

(3) **Généralisation géographique** : les modèles sont calibrés sur 6 zones sénégalaises(Dakar_keurmassar,Kaolack_leaona,Diourbel_Touba,Saintlouis,Matam,Kolda,T

ambacounda). Leur transfert vers d'autres pays sahéliens nécessiterait une recalibration des seuils et idéalement un ré-entraînement partiel [Nicholson 2013].

3.5 Synthèse des Résultats

Le Random Forest atteint un rappel de 100 % (FN=0, AUC-ROC=1,000) sur 2 202 observations de test et une robustesse confirmée sur 5 folds temporels. Sur les 113 images de validation du corpus CNN (67 inondations, 46 normales), ConvNeXt-Tiny obtient le meilleur F1-Score (96,48 %), le meilleur AUC-ROC (0,9877) et **zéro fausse alerte** (FP=0). La combinaison RF + ConvNeXt forme un pipeline où le RF signale tous les risques météorologiques et ConvNeXt valide chaque image citoyenne sans déclencher d'alerte injustifiée.

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne




Figure 3.9 : Pipeline opérationnel. Données météo → RF (Rappel=100%) → Image citoyenne → ConvNeXt (FP=0) → Alerte autorités.

Conclusion Générale

1. Rappel de la Problématique et des Objectifs

Les inondations constituent l'une des catastrophes naturelles les plus fréquentes et les plus dévastatrices au Sénégal, particulièrement dans les zones périurbaines de Dakar et les villes secondaires du bassin arachidier [Fall et al. 2006]. Leur gestion repose encore largement sur des réactions post-événement, faute d'outils d'anticipation adaptés aux contraintes locales : données institutionnelles fragmentaires, faible densité du réseau de mesure et infrastructure numérique limitée.

Ce mémoire a proposé une réponse à cette problématique en développant un **système hybride à deux composantes complémentaires** : (1) un modèle Random Forest pour la prédiction météorologique précoce à partir de réanalyses horaires Open-Meteo, et (2) un réseau convolutif ConvNeXt-Tiny pour la validation visuelle de signalements citoyens géolocalisés. Les deux modèles sont intégrés dans une plateforme collaborative dont les prototypes d'interface sont présentés en Annexe C.

2. Bilan des Résultats Obtenus

Composante météorologique (Random Forest). Sur un ensemble de test temporellement indépendant couvrant 2 202 observations journalières (2023–2025), le Random Forest atteint un rappel de 100 % avec un seul faux positif. L'AUC-ROC de 1,000 et la moyenne de 0,9999 sur cinq folds de validation croisée temporelle (TimeSeriesSplit) confirment une **généralisation robuste sur 15 années de données non vues**. La variable la plus prédictive est le cumul pluviométrique sur 3 jours (47,7 % de l'importance Gini), ce qui valide l'hypothèse hydrologique fondamentale: les inondations résultent d'une saturation progressive du sol plutôt que d'un événement intense isolé [Nicholson 2013].

Composante visuelle (ConvNeXt-Tiny). Sur les 113 images de validation (67 scènes d'inondation, 46 scènes normales), ConvNeXt-Tiny obtient un F1-Score de 96,48 %, un AUC-ROC de 0,9877, et surtout **zéro fausse alerte (FP = 0)** — propriété critique pour préserver la confiance des autorités dans le système. Swin-Tiny affiche un meilleur rappel d'inondation (98,51 % contre 94,03 %), mais génère 4 fausses alertes contre 0, et son instabilité à l'entraînement (chutes en P1-5 et P2-1) est moins souhaitable en production. EfficientNet-B3 et ResNet-18 constituent des références utiles mais insuffisantes pour un déploiement opérationnel.

Composante	Modèle	Résultat clé	Propriété opérationnelle
Météorologique	Random Forest (400 arbres)	AUC-ROC = 1,000 Recall = 100 %	Aucune inondation non-alertée (FN = 0)
Visuelle	ConvNeXt-Tiny (27,8 M params)	F1 = 96,48 % AUC = 0,9877	Aucune fausse alerte (FP = 0)

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

Composante	Modèle	Résultat clé	Propriété opérationnelle
Robustesse	TimeSeriesSplit (5 folds)	AUC moyen = 0,9999 ± 0,0001	Stabilité sur 15 ans de données
Explicabilité	Importance RF + Grad-CAM	precip_3d_sum = 47,7 %	Interprétabilité pour les décideurs

Tableau C.G.1 : Synthèse des résultats des deux composantes du système.

3. Contributions Principales

Contribution méthodologique. La définition de la variable cible *flood_risk* par double seuil percentile (P97 journalier et P95 sur 3 jours glissants, calibrés par zone) constitue une contribution originale adaptée au contexte sénégalais, où aucune base d'inondations géolocalisées et exhaustives n'est disponible [Mosavi et al. 2018]. Cette approche proxy est reproductible pour d'autres zones sahéliennes disposant de réanalyses horaires.

Contribution expérimentale. L'étude comparative rigoureuse de quatre architectures CNN modernes (ResNet-18, EfficientNet-B3, ConvNeXt-Tiny, Swin-Tiny) sous protocole identique — même dataset augmenté (820 images train), même configuration AdamW, même protocole 3 phases — constitue, à notre connaissance, la première comparaison systématique de ce type appliquée à la détection visuelle d'inondations en contexte urbain sénégalais.

Contribution applicative. La plateforme web collaborative (Annexe C) intègre les deux modèles dans un flux de décision cohérent : signalement citoyen → validation ConvNeXt → croisement RF → alerte qualifiée aux autorités. Ce prototype démontre la faisabilité d'un système d'alerte précoce basé sur la synergie données météorologiques/intelligence citoyenne, adapté aux contraintes institutionnelles et infrastructurelles du Sénégal.

4. Limites et Travaux Futurs

Taille du dataset visuel. Le corpus d'images (933 images après augmentation, 113 en validation) reste modeste au regard des standards des benchmarks de détection [Gebrehiwot et al. 2019]. Les 4 faux négatifs de ConvNeXt-Tiny correspondent vraisemblablement à des scènes visuellement ambiguës que seul un corpus plus large permettrait de mieux couvrir. La collecte continue via la plateforme citoyenne est la voie la plus réaliste pour enrichir ce corpus dans le contexte sénégalais.

Validation du proxy d'inondation. La variable cible *flood_risk* repose sur un proxy pluviométrique (double seuil percentile). Sa calibration sur des événements réels géolocalisés, en partenariat avec la Direction de la Protection Civile ou l'ONAS, constituerait un apport majeur pour renforcer la validité externe du modèle RF.

Généralisation géographique. Les modèles sont calibrés sur 6 zones sénégalaises. Leur transfert à d'autres pays sahéliens (Mauritanie, Mali, Niger) nécessiterait une recalibration des

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

seuils pluviométriques et, pour le volet CNN, un ré-entraînement partiel sur des images locales [Liu et al. 2022].

Fusion non évaluée expérimentalement. Le moteur de règles fusionnant les scores RF et ConvNeXt est implémenté dans la plateforme mais n'a pas fait l'objet d'une évaluation expérimentale quantitative dans ce mémoire. Une étude prospective mesurant la réduction du taux de fausse alerte global grâce à la fusion constitue une piste de recherche directe.

Perspectives à court terme. Trois axes d'extension sont envisageables : (1) intégration de données satellites (Sentinel-1 SAR) pour la détection d'eau libre en zones rurales inaccessibles aux signalements citoyens ; (2) adaptation du modèle CNN à la détection multi-classe (inondation sévère / modérée / normale) ; (3) déploiement d'une API temps réel couplée aux prévisions météo Open-Meteo pour générer des alertes préventives 24 à 48 heures à l'avance.

5. Réflexion Finale

Ce mémoire illustre qu'une approche hybride ML + DL, rigoureusement validée et ancrée dans les contraintes locales, peut produire des outils d'aide à la décision à la fois performants et interprétables. Le Random Forest, souvent présenté comme une méthode classique, démontre ici une capacité de généralisation remarquable sur 20 années de données climatiques hétérogènes. ConvNeXt-Tiny, architecture moderne fondée sur les principes des Transformers, s'adapte efficacement à un corpus d'images limité grâce au transfer learning progressif.

Au-delà des chiffres, ce travail pose une question essentielle pour la recherche appliquée en Afrique subsaharienne : comment mobiliser l'intelligence artificielle au service de populations exposées à des risques majeurs, dans des contextes où les données institutionnelles sont rares et les ressources computationnelles limitées ? La réponse proposée ici — combinaison de données ouvertes, d'augmentation hors-ligne, de transfer learning et d'engagement citoyen — constitue une piste transférable bien au-delà du seul cas des inondations au Sénégal.

Résultat synthétique du système

Random Forest : Recall = 100 % | AUC-ROC = 1,000 | FN = 0 sur 2 202 observations (2023–2025)

ConvNeXt-Tiny : F1 = 96,48 % | AUC-ROC = 0,9877 | FP = 0 sur 113 images de validation

Plateforme : signalement citoyen géolocalisé → validation IA → alerte qualifiée aux autorités

BIBLIOGRAPHIE

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

- [Bonafilia et al. 2020] D. Bonafilia et al., "Sen1Floods11: a georeferenced dataset to train and test deep learning flood algorithms," Proc. IEEE CVPR Workshops, 2020.
- [Breiman 2001] L. Breiman, "Random forests," Machine Learning, vol. 45, no. 1, pp. 5–32, 2001.
- [Chawla et al. 2002] N. V. Chawla et al., "SMOTE: Synthetic Minority Over-sampling Technique," Journal of Artificial Intelligence Research, vol. 16, pp. 321–357, 2002.
- [Chen & Guestrin 2016] T. Chen et C. Guestrin, "XGBoost: A scalable tree boosting system," Proc. ACM KDD, pp. 785–794, 2016.
- [Cour des Comptes 2022] Cour des Comptes du Sénégal, "Rapport sur le Programme Décennal de Gestion des Inondations," Dakar, 2022.
- [Hochreiter & Schmidhuber 1997] S. Hochreiter et J. Schmidhuber, "Long Short-Term Memory," Neural Computation, vol. 9, no. 8, pp. 1735–1780, 1997.
- [Fall et al. 2006] A. S. Fall, I. M. Cissé et C. O. Bâ, "Les inondations à Dakar et banlieue : causes et impacts," Environnement Urbain, vol. 1, 2006.
- [Gebrehiwot et al. 2019] A. Gebrehiwot et al., "Deep learning approach for flood detection using ResNet-50," Int. J. Disaster Risk Reduction, vol. 38, 2019.
- [Geurts et al. 2006] P. Geurts, D. Ernst et L. Wehenkel, "Extremely randomized trees," Machine Learning, vol. 63, no. 1, pp. 3–42, 2006.
- [GIEC 2021] Groupe d'experts intergouvernemental sur l'évolution du climat, "Sixième rapport d'évaluation," 2021.
- [Goodchild 2007] M. F. Goodchild, "Citizens as sensors: the world of volunteered geography," GeoJournal, vol. 69, no. 4, pp. 211–221, 2007.
- [He et al. 2016] K. He et al., "Deep residual learning for image recognition," Proc. IEEE CVPR, pp. 770–778, 2016.
- [Huang et al. 2016] G. Huang et al., "Deep networks with stochastic depth," Proc. ECCV, pp. 646–661, 2016.
- [Hyndman & Athanasopoulos 2018] R. J. Hyndman et G. Athanasopoulos, "Forecasting: Principles and Practice," 2e éd., OTexts, 2018.
- [LeCun et al. 2015] Y. LeCun, Y. Bengio et G. Hinton, "Deep learning," Nature, vol. 521, pp. 436–444, 2015.

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

- [Leite et al. 2010] R. P. Leite et al., "Data leakage in cross-validation," arXiv:1012.0839, 2010.
- [Liu et al. 2021] Z. Liu et al., "Swin Transformer: Hierarchical Vision Transformer using Shifted Windows," Proc. ICCV, pp. 10012–10022, 2021.
- [Liu et al. 2022] Z. Liu et al., "A ConvNet for the 2020s," Proc. IEEE CVPR, pp. 11976–11986, 2022.
- [Loshchilov & Hutter 2019] I. Loshchilov et F. Hutter, "Decoupled weight decay regularization," ICLR 2019.
- [Meier 2012] P. Meier, "Crisis mapping in action: How open source software and global volunteer networks are changing the world," Journal of Map and Geography Libraries, vol. 8, no. 2, 2012.
- [Mosavi et al. 2018] A. Mosavi, P. Ozturk et K.-W. Chau, "Flood prediction using machine learning models," Water, vol. 10, 1536, 2018.
- [Nicholson 2013] S. E. Nicholson, "Rainfall variability in the West African Sahel," ISRN Meteorology, 2013.
- [OCHA 2012] Bureau de la Coordination des Affaires humanitaires des Nations Unies, "Sénégal : Rapport de situation sur les inondations," 2012.
- [Open-Meteo 2025] Open-Meteo, "Historical Weather API," 2025. <https://open-meteo.com>
- [ONU-Habitat 2020] Programme des Nations Unies pour les établissements humains, "World Cities Report 2020," Nairobi, 2020.
- [Pan & Yang 2010] S. J. Pan et Q. Yang, "A survey on transfer learning," IEEE TKDE, vol. 22, no. 10, pp. 1345–1359, 2010.
- [Pedregosa et al. 2011] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," JMLR, vol. 12, pp. 2825–2830, 2011.
- [Powers 2011] D. M. W. Powers, "Evaluation: From precision, recall and F-measure to ROC," JMLT, vol. 2, no. 1, pp. 37–63, 2011.
- [Selvaraju et al. 2020] R. R. Selvaraju et al., "Grad-CAM," Int. J. Computer Vision, vol. 128, pp. 336–359, 2020.

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

- [Shorten & Khoshgoftaar 2019] C. Shorten et T. M. Khoshgoftaar, "A survey on image data augmentation," *Journal of Big Data*, vol. 6, p. 60, 2019.
- [Simonyan & Zisserman 2014] K. Simonyan et A. Zisserman, "Very deep convolutional networks for large-scale image recognition," *arXiv:1409.1556*, 2014.
- [Smith 2018] L. N. Smith, "A disciplined approach to neural network hyper-parameters," *arXiv:1803.09820*, 2018.
- [Srivastava et al. 2014] N. Srivastava et al., "Dropout: A simple way to prevent neural networks from overfitting," *JMLR*, vol. 15, pp. 1929–1958, 2014.
- [Szegedy et al. 2016] C. Szegedy et al., "Rethinking the inception architecture," *Proc. CVPR*, pp. 2818–2826, 2016.
- [Tan & Le 2019] M. Tan et Q. V. Le, "EfficientNet: Rethinking model scaling," *Proc. ICML*, pp. 6105–6114, 2019.
- [Tehrany et al. 2019] M. S. Tehrany, B. Pradhan et M. N. Jebur, "Flood susceptibility mapping using a novel ensemble weights-of-evidence and support vector machine models," *Geoscience Frontiers*, 2019.
- [Tikhonov 1963] A. N. Tikhonov, "Solution of incorrectly formulated problems," *Soviet Mathematics*, vol. 4, 1963.
- [UNDRR 2006] United Nations Office for Disaster Risk Reduction, "Global Survey of Early Warning Systems," 2006.
- [Wang et al. 2015] Z. Wang et al., "Flood hazard assessment using Random Forest," *J. Hydrology*, vol. 527, pp. 595–607, 2015.
- [Yosinski et al. 2014] J. Yosinski et al., "How transferable are features in deep neural networks?" *NeurIPS 2014*, pp. 3320–3328.
- [Yun et al. 2019] S. Yun et al., "CutMix: Regularization strategy," *Proc. ICCV*, pp. 6023–6032, 2019.
- [Zhang et al. 2018] H. Zhang et al., "Mixup: Beyond empirical risk minimization," *ICLR 2018*.

Annexes

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

Annexe A — Détails techniques du modèle Random Forest (données, hyperparamètres, résultats complémentaires)

Annexe B — Détails techniques de la comparaison CNN (4 architectures, configuration, résultats)

Annexe C — Plateforme web collaborative de signalement et d'aide à la décision

ANNEXE A — Détails Méthodologiques et Résultats

Complémentaires du Modèle Random Forest

Cette annexe regroupe les éléments techniques du modèle Random Forest présentés aux sections 2.2 et 3.1, volontairement non détaillés dans le corps du mémoire afin d'en préserver la lisibilité. Toutes les valeurs sont extraites du notebook *model.ipynb*.

A.1 — Source et Période des Données

Source : Open-Meteo Historical Weather API — <https://open-meteo.com/en/docs/historical-weather-api>

Résolution initiale : horaire, agrégée à l'échelle journalière (mois de saison des pluies uniquement : juin à octobre)

Période couverte : 7 avril 2005 → 31 juillet 2025

Zone	Début	Fin	Observations horaires	Durée (jours)
Kaolack (Leona)	2005-04-07	2025-07-31	178 104	7 420
Keur Massar	2005-04-07	2025-07-31	178 104	7 420
Kolda	2005-04-07	2025-07-31	178 104	7 420
Matam	2005-04-07	2025-07-31	178 104	7 420
Tambacounda	2005-04-07	2025-07-31	178 104	7 420
Touba	2005-04-07	2025-07-31	178 104	7 420

Tableau A.1 : Zones géographiques et volume de données brutes. Source : *model.ipynb*, Cellule 4.

A.2 — Variables Explicatives Sélectionnées (SELECTED_FEATURES)

Les 9 variables ci-dessous sont les seules passées au modèle Random Forest, définies dans la variable *SELECTED_FEATURES* (Cellule 4, *model.ipynb*). Les variables saisonnières (*is_rainy_season*, *dayofyear_sin/cos*) sont calculées dans le pipeline mais **exclues de SELECTED_FEATURES** après analyse d'importance.

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

Rang	Variable	Type	Corrélation cible (Cellule 38)
1	precip_3d_sum	Cumul 3 jours	0,726 ★
2	precipitation_mm_sum	Journalier	0,582
3	precip_7d_sum	Cumul 7 jours	0,557
4	precipitation_mm_max	Journalier max	0,478
5	precip_15d_sum	Cumul 15 jours	0,432
6	temperature_2m_degc_max	Climatique	−0,326
7	temperature_2m_degc_mean	Climatique	−0,304
8	relative_humidity_2m_pct_mean	Climatique	0,277
9	relative_humidity_2m_pct_max	Climatique	0,169

Tableau A.2 : Variables sélectionnées par `SELECTED_FEATURES`. Source : `model.ipynb`, Cellules 4 et 38.

A.3 — Répartition des Données d'Apprentissage et de Test

La séparation est **temporellement stricte** : données antérieures au 1er janvier 2023 pour l'entraînement, données 2023–2025 pour le test. Aucun split aléatoire n'est effectué (prévention de la fuite d'information [Leite et al. 2010]).

Classe	Entraînement (2005–2022)	Test (2023–2025)	Total
0 — Non-inondation	15 494	1 999	17 493
1 — Inondation	1 030	203	1 233
Total	16 524	2 202	18 726

Tableau A.3 : Répartition des observations journalières. Source : `model.ipynb`, Output Cellule 16.

Gestion du déséquilibre — `class_weight`, pas SMOTE

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

Le déséquilibre (~6 % de jours à risque) est géré par `class_weight='balanced_subsample'` du `RandomForestClassifier`, qui pondère chaque arbre proportionnellement à l'inverse des fréquences de classe. SMOTE n'est pas utilisé : la nature temporelle des données interdirait la génération d'observations interpolées sans créer de fuite d'information [Leite et al. 2010].

A.4 — Hyperparamètres du Modèle Random Forest

Paramètre	Valeur	Justification
<code>n_estimators</code>	400	Stabilité variance-biais
<code>max_depth</code>	10	Prévention surapprentissage
<code>min_samples_leaf</code>	5	Robustesse aux outliers
<code>max_features</code>	$\sqrt{n_features}$ (défaut)	Sélection aléatoire par arbre
<code>class_weight</code>	'balanced_subsample'	Gestion déséquilibre 6/94 %
<code>random_state</code>	42	Reproductibilité
<code>n_jobs</code>	-1	Parallélisation complète
Seuil de décision	0,350	Optimisé sur courbe PR (Cellule 42)

Tableau A.4 : Hyperparamètres du Random Forest. Source : *model.ipynb*, Cellule 21.

A.5 — Performances Globales sur le Jeu de Test

Métrique	Valeur
AUC-ROC	1,0000
Average Precision	1,0000
Recall	1,0000 — FN = 0
Precision	0,9951
F1-Score	0,9975
Accuracy	0,9995

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

Métrique	Valeur
Seuil de décision (probabilité)	0,350
Seuil pluie 1j (P97)	20,3 mm
Seuil pluie 3j cumulés (P95)	39,0 mm
Support positif / total	203 / 2 202

Tableau A.5 : Métriques complètes. Source : *model.ipynb*, Output Cellule 42.

A.6 — Matrice de Confusion Détaillée

	Prédit : Non-risque	Prédit : Risque
Réel : Non-risque	VN = 1 998	FP = 1
Réel : Risque	FN = 0	VP = 203

Tableau A.6 : Matrice de confusion —test 2023–2025. 1 seule fausse alerte sur 2 202 observations. Source : *model.ipynb*, Cellule 25.

Ces résultats confirment que le modèle présente une capacité de détection maximale des événements à risque (Recall = 100 %, FN = 0), tout en maintenant un taux de fausses alertes quasi nul (FP = 1 sur 2 202 observations).

A.7 — Importance des Variables (Gini)

Rang	Variable	Importance Gini	Cumul
1	precip_3d_sum	47,7 %	47,7 %
2	precip_7d_sum	21,3 %	69,0 %
3	precipitation_mm_sum	9,3 %	78,3 %
4	precip_15d_sum	7,9 %	86,2 %
5	temperature_2m_degc_mean	5,3 %	91,5 %
6	relative_humidity_2m_pct_mean	4,4 %	95,9 %
7	precipitation_mm_max	2,3 %	98,2 %

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

Rang	Variable	Importance Gini	Cumul
8	temperature_2m_degc_max	1,8 %	100,0 %
9	relative_humidity_2m_pct_max	<0,1 %	100,0 %

Tableau A.7 : Importance Gini par rang. Les cumuls multi-jours représentent 86,2 % de l'importance totale.

A.8 — Validation Croisée Temporelle (TimeSeriesSplit, 5 Folds)

Fold	Période test	Jours risque	AUC-ROC	Précision	Recall	F1
1	2008–2010	197 / 2 754	0,9997	94,03 %	95,94 %	94,97 %
2	2011–2013	161 / 2 754	0,9999	95,83 %	100,00 %	97,87 %
3	2014–2016	145 / 2 754	1,0000	98,64 %	100,00 %	99,32 %
4	2017–2019	186 / 2 754	1,0000	97,89 %	100,00 %	98,94 %
5	2020–2022	226 / 2 754	1,0000	97,84 %	100,00 %	98,91 %
Moy. ± σ	—	—	0,9999 ± 0,0001	96,85 % ± 1,7	99,19 % ± 1,8	98,00 % ± 1,7

Tableau A.8 : Validation croisée temporelle (TimeSeriesSplit, 5 folds).

Ces résultats démontrent une stabilité temporelle élevée du modèle.

A.9 — Extraits de Code Clé (model.ipynb)

A.9.1 — SELECTED_FEATURES et seuil de décision (Cellule 4 et Cellule 42)

```
SELECTED_FEATURES = [
    'precipitation_mm_sum',    # cumul journalier total
    'precipitation_mm_max',    # maximum horaire de la journée
    'relative_humidity_2m_pct_mean',
    'relative_humidity_2m_pct_max',
    'temperature_2m_degc_mean',
    'temperature_2m_degc_max',
    'precip_3d_sum',           # cumul glissant 3 jours (feature n°1)
    'precip_7d_sum',           # cumul glissant 7 jours
    'precip_15d_sum',          # cumul glissant 15 jours
```

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

```
]
```

```
SEUIL_OPTIMAL = 0.350      # optimisé sur courbe Précision-Rappel (Cellule 42)
```

```
RAINY_MONTHS = {6, 7, 8, 9, 10} # seule la saison des pluies est modélisée
```

A.9.2 — Configuration et entraînement du Random Forest (Cellule 21)

```
rf = RandomForestClassifier(  
    n_estimators    = 400,  
    max_depth      = 10,  
    min_samples_leaf = 5,  
    class_weight    = 'balanced_subsample',  
    random_state    = 42,  
    n_jobs          = -1,  
)  
rf.fit(train_X, train_y)  
test_pred = (rf.predict_proba(test_X)[: , 1] >= SEUIL_OPTIMAL).astype(int)
```

A.9.3 — Organisation des fichiers

```
memoire/  
donnee/  
    inondation_senegal/  
        *.csv      # données horaires Open-Meteo par zone  
models/  
    random_forest_predict_model.pkl  
    scaler_predict.pkl  
    flood_predict_metadata.json  
notebooks/  
    model.ipynb    # Random Forest complet
```

Le code source complet est disponible dans le dépôt GitHub du projet. (<https://github.com/ahmadous>)

ANNEXE B — Détails Méthodologiques et Résultats

Complémentaires de la Comparaison CNN

Cette annexe présente les éléments techniques de l'étude comparative des quatre architectures CNN (sections 2.3 et 3.2). Le modèle retenu pour le déploiement est **ConvNeXt-Tiny**, en remplacement de ResNet-18 qui figurait dans la version initiale du mémoire. Toutes les valeurs sont extraites du notebook *flood_comparison.ipynb*.

Changement par rapport à la version initiale du mémoire

La version initiale présentait ResNet-18 comme modèle de détection visuelle unique. L'étude comparative (Chapitre 3, Section 3.2) a montré que ConvNeXt-Tiny obtient de meilleures performances globales (F1=96,48 %, FP=0) avec un protocole d'entraînement en 3 phases. ConvNeXt-Tiny est donc le modèle intégré à la plateforme (Annexe C).

B.1 — Constitution du Jeu de Données d'Images

Dataset original : 410 images équilibrées à 50/50 — 205 scènes d'inondation + 205 scènes normales.

Source	Part	Nature
Banques d'images Creative Commons vérifiées	~40 %	Labels tiers validés
Signalements citoyens révisés manuellement	~35 %	Annotations manuelles
Collectes spécialisées 2024–2025	~25 %	Photos terrain Sénégal

Tableau B.1 : Sources du dataset d'images.

Ensemble	Images	Composition	Remarque
Train (dossier /train)	820	410 flood + 410 normale	Après augmentation offline (target_per_class=410)
Val (dossier /val)	113	67 flood + 46 normale	Images originales non-augmentées
Dataset brut	410	205 + 205	Avant augmentation

Tableau B.2 : Répartition train/val. Source : *flood_comparison.ipynb*, Output Cellule 5.

B.2 — Prétraitement et Augmentation des Données

Augmentation hors-ligne (offline) — avant entraînement : la fonction `augment_train_set(..., target_per_class=410)` génère et sauvegarde des images sur disque jusqu'à 410 images par classe :

```
# Pipeline augmentation OFFLINE (sauvegarde sur disque)
augmentation = transforms.Compose([
    transforms.RandomRotation(25),
    transforms.RandomHorizontalFlip(p=1.0),
    transforms.ColorJitter(brightness=0.3, contrast=0.3, saturation=0.2),
    transforms.RandomAffine(degrees=0, translate=(0.1, 0.1)),
])
aug_img.save(save_path) # sauvegarde physique sur disque
```

Augmentation à la volée (on-the-fly) — pendant l'entraînement :

```
# Pipeline augmentation ON-THE-FLY (train_transform, Cellule 5)
train_transform = transforms.Compose([
    transforms.Resize((256, 256)),
    transforms.RandomCrop((224, 224)),
    transforms.RandomHorizontalFlip(p=0.5),
    transforms.RandomVerticalFlip(p=0.3),
    transforms.RandomRotation(degrees=30),
    transforms.RandomAffine(degrees=0, translate=(0.1,0.1), scale=(0.85,1.15), shear=10),
    transforms.ColorJitter(brightness=0.4, contrast=0.4, saturation=0.3, hue=0.1),
    transforms.RandomGrayscale(p=0.05),
    transforms.GaussianBlur(kernel_size=3, sigma=(0.1,1.5)),
    transforms.RandomPerspective(distortion_scale=0.2, p=0.3),
    transforms.ToTensor(),
    transforms.Normalize(mean=[0.485,0.456,0.406], std=[0.229,0.224,0.225]),
    transforms.RandomErasing(p=0.2, scale=(0.02,0.1))
])
```

```

))
# + Mixup (alpha=0.4) et CutMix (alpha=1.0) appliqués dans train_epoch()

```

B.3 — Configuration d'Entraînement Commune aux 4 Modèles (CONFIG)

Hyperparamètres définis dans la Cellule 3 du notebook *flood_comparison.ipynb*, identiques pour les 4 architectures :

Paramètre	Valeur	Description
batch_size	16	Taille de batch
img_size	224	Résolution entrée (224×224 px)
phase1_epochs	5	Backbone gelé + LR warmup linéaire
phase2_epochs	8	Couches profondes dégelées + CosineAnnealing
phase3_epochs	12	Fine-tuning réseau complet
phase1_lr	1e-3	LR maximum Phase 1
phase2_lr	1e-4	LR initial Phase 2
phase3_lr	3e-5	LR initial Phase 3
weight_decay	0,02	L2 AdamW découplé [Loshchilov & Hutter 2019]
patience	7	Early stopping (min_delta=0,001)
mixup_alpha	0,4	Paramètre Beta Mixup [Zhang et al. 2018]
cutmix_alpha	1,0	Paramètre Beta CutMix [Yun et al. 2019]
Optimiseur	AdamW	Weight decay découplé
Loss	CrossEntropyLoss	Avec class_weights tensor([2., 2.])

Tableau B.3 : CONFIG partagée par les 4 modèles. Source : *flood_comparison.ipynb*, Cellule 3.

B.4 — Architecture FloodClassifier et Protocole 3 Phases

```

class FloodClassifier(nn.Module):
    # Encapsule timm.create_model(model_name, pretrained=True, num_classes=2)

```

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

```
def freeze_backbone(self): # Phase 1 : tête seule entraînable
    # head_keywords = ['fc','head','classifier','last_linear']

def unfreeze_deep(self): # Phase 2 : couches profondes dégelées
    # deep_keywords = ['layer4','blocks.5-7','stages.3','layers.3',...]

def unfreeze_all(self): # Phase 3 : réseau complet

# Optimiseur par phase : AdamW(weight_decay=0.02)
# Phase 1 : LambdaLR (warmup linéaire 1e-6 → 1e-3 sur 5 epochs)
# Phase 2 : CosineAnnealingLR (1e-4 → 0 sur 8 epochs)
# Phase 3 : CosineAnnealingLR (3e-5 → 0 sur 12 epochs)
# Early Stopping : patience=7, min_delta=0.001, sauvegarde best model
```

B.5 — Résultats Complets des 4 Architectures (Cellule 15)

Métrique	ResNet-18	EfficientNet-B3	ConvNeXt-Tiny	Swin-Tiny
Accuracy (%)	79,65	90,27	96,46	95,58
Precision weighted (%)	80,57	91,58	96,74	95,67
Recall weighted (%)	79,65	90,27	96,46	95,58
F1-Score weighted (%)	79,80	90,35	96,48	95,55
AUC-ROC	0,8897	0,9588	0,9877	0,9812
Recall Inondation (%)	77,61	85,07	94,03	98,51
TP / FN (sur 67 flood)	52 / 15	57 / 10	63 / 4	66 / 1
FP / TN (sur 46 normales)	8 / 38	1 / 45	0 / 46	4 / 42
Phases complétées	P1+P2	P1+P2+P3	P1+P2+P3	P1+P2
Early stop	P2-epoch 7	P3-epoch 12	Aucun	P2-epoch 7
Paramètres (M)	11,2	10,7	27,8	27,5
Temps d'entraînement	2,7	5,8	7,1	3,0

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

Métrique	ResNet-18	EfficientNet-B3	ConvNeXt-Tiny	Swin-Tiny
(min)				

Tableau B.4 : Résultats complets des 4 modèles sur 113 images de validation (67 flood + 46 normal). Valeurs exactes Cellule 15. Matrices déduites des métriques.

B.6 — Couches Cibles Grad-CAM (Cellule 21)

Modèle	Couche cible dans le code	Justification
ResNet-18	model.layer4[-1].conv2	Dernière conv du bloc résiduel profond
EfficientNet-B3	model.blocks[-1][-1].conv_pwl	Dernière conv pointwise du dernier bloc
ConvNeXt-Tiny	model.stages[-1].blocks[-1].conv_dw	Conv depth-wise du dernier stage
Swin-Tiny	model.layers[-1].blocks[-1].norm1	Normalisation finale (proxy spatial)

Tableau B.5 : Couches cibles Grad-CAM. Paramètre errors_only=True : images sélectionnées parmi les erreurs de classification.

B.7 — Organisation des Fichiers et Reproductibilité

```
memoire/  
  donnee/  
    inondation_senegal/  
      flood_dataset/  
        train/  
          inondation/ # 410 images (après augmentation offline)  
          non_inondation/ # 410 images (après augmentation offline)  
        val/  
          inondation/ # 67 images originales  
          non_inondation/ # 46 images originales  
      notebooks/  
        flood_comparison.ipynb # Comparaison 4 architectures
```

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

```
model.ipynb      # Random Forest
models/
flood_model_convnext.pth # Poids ConvNeXt-Tiny (Cellule 24)
model_config.json  # Configuration sauvegardée
```

Le code source complet est disponible dans le dépôt GitHub du projet. (<https://github.com/ahmadous>)

ANNEXE C — Plateforme Collaborative de Signalement et d'Aide à la Décision

Cette annexe présente la plateforme web développée en complément des modèles IA. Elle constitue la couche applicative du système : collecte des signalements citoyens, invocation des deux modèles, et tableau de bord pour les autorités. Elle est distincte des notebooks d'entraînement documentés en Annexes A et B.

Note sur le périmètre expérimental

Les modèles RF et ConvNeXt sont évalués indépendamment dans les Chapitres 2 et 3. Leur intégration dans la plateforme via un moteur de règles (Si Vision=Inondé ET Risque Météo > Seuil ALORS Priorité Haute) est implémentée dans la couche applicative — elle ne fait pas l'objet d'une évaluation expérimentale dans ce mémoire.

C.1 — Objectifs Fonctionnels de la Plateforme

La plateforme a été conçue comme un outil d'aide à la décision visant à :

- (1) **Collecte citoyenne géolocalisée** : permettre à tout citoyen de signaler une inondation avec image et position GPS via smartphone.
- (2) **Validation automatique IA** : analyser chaque image par ConvNeXt-Tiny et croiser avec le risque météo RF pour qualifier l'alerte.
- (3) **Tableau de bord autorités** : fournir aux maires et services techniques une vue consolidée et priorisée des situations à risque.
- (4) **Traçabilité** : historiser l'ensemble des signalements, validations et actions pour audit et amélioration continue.

L'objectif n'est pas de remplacer les dispositifs institutionnels existants, mais de compléter les systèmes d'alerte par une couche numérique collaborative et intelligente.

C.2 — Rôles et Profils Utilisateurs

Profil	Fonctions principales	Accès
Citoyen	Soumettre signalement (image + GPS) — consulter alertes — recevoir notifications	Public authentifié

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

Profil	Fonctions principales	Accès
Autorité locale	Alertes par priorité — valider/rejeter signalements — ajouter commentaires — suivre évolution	Rôle restreint
Administrateur	Supervision globale — gestion utilisateurs — configuration seuils et paramètres	Rôle système

Tableau C.1 : Rôles et droits utilisateurs.

C.3 — Architecture Technique de la Plateforme

Composant	Technologie	Rôle
Frontend web	Vue.js (mobile-first)	Interface citoyens et autorités
API Gateway	REST	Point d'entrée unique
Microservice RF	Flask + random_forest_predict_model.pkl	Prédiction météorologique
Microservice ConvNeXt	Flask + flood_model_convnext.pth	Détection visuelle (remplace ResNet-18)
Base de données temps réel	Firebase Firestore	Synchronisation alertes en temps réel
Cartographie	GéoSénégal (portail national)	Visualisation zones à risque

Tableau C.2 : Composants techniques. Architecture inspirée des microservices, adaptée à un prototype académique.

C.4 — Flux de Traitement d'un Signalement

Étape	Action	Acteur
1	Soumission d'un signalement avec image et position GPS	Citoyen
2	Analyse de l'image par ConvNeXt-Tiny → classe + score de confiance	Système IA
3	Évaluation du risque météo par RF pour la zone GPS → probabilité	Système IA
4	Moteur de règles : fusion des scores → niveau de priorité	Plateforme

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

Étape	Action	Acteur
	(Haute/Moyenne/Basse)	
5	Stockage dans Firestore, notification envoyée aux autorités compétentes	Plateforme
6	Consultation, validation ou rejet du signalement par l'autorité	Autorité locale
7	Statut mis à jour, visible par tous les utilisateurs concernés	Plateforme

Tableau C.3 : Flux de traitement d'un signalement citoyen. Note : ConvNeXt-Tiny remplace ResNet-18 dans ce flux par rapport à la version initiale du mémoire.

C.5 — Données Géographiques et Visualisation

Les alertes sont visualisées sur une carte interactive intégrant les signalements citoyens, les zones inondables, et les couches hydrologiques et urbaines pertinentes. Les données géographiques proviennent du portail national GéoSénégal et sont utilisées exclusivement à des fins de visualisation, sans intervenir directement dans les modèles IA.

C.6 — Sécurité, Traçabilité et Limites

La plateforme intègre une authentification des utilisateurs, un historique des actions et une séparation stricte des droits d'accès. Trois limites principales sont identifiées :

- (1) **Déploiement à grande échelle** : une interconnexion institutionnelle formelle avec la Direction de la Protection Civile serait requise.
- (2) **Validation en conditions réelles** : les modèles ont été évalués sur un ensemble de validation contrôlé ; des tests de terrain restent nécessaires.
- (3) **Gouvernance des données** : une stratégie de maintenance des données citoyennes doit être définie avant tout déploiement institutionnel.

C.7 — Reproductibilité et Extension


Le code source de la plateforme (API, interfaces Vue.js, scripts de déploiement) est disponible dans le dépôt GitHub du projet. Les poids du modèle ConvNeXt-Tiny sont

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne


exportés sous `flood_model_convnext.pth` (Cellule 24, `flood_comparison.ipynb`) et la configuration sous `model_config.json`.

C.8 — Illustrations de la Plateforme (Captures d'Écran)

Les figures ci-dessous présentent les principales interfaces de la plateforme. Elles sont fournies à titre illustratif et ne constituent pas des résultats expérimentaux.




Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne



Interface de signalement d'une inondation par un citoyen (a) Formulaire de saisie (b) Géolocalisation (c) Téléversement image (d) Confirmation


Figure C.1 : Interface de signalement d'une inondation par un citoyen



Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

Résultat de la classification visuelle par ConvNeXt-Tiny lors d'un signalement (remplace ResNet-18 — version initiale du mémoire)

Figure C.2 : Résultat de la classification visuelle par ConvNeXt-Tiny lors d'un signalement



Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne





Tableau de bord des autorités locales — vue consolidée des alertes par priorité


Figure C.3 : Tableau de bord des autorités locales — vue consolidée des alertes par priorité

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne




Validation d'un signalement par une autorité locale

Figure C.4 : Validation d'un signalement par une autorité locale



Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne



Interface cartographique — alertes validées et couches géographiques (GéoSénégal) Axes d'écoulement, bassins, zones inondables, eaux permanentes

Figure C.5 : Interface cartographique — alertes validées et couches géographiques (GéoSénégal)



Prédiction automatique du risque d'inondation (composante Random Forest intégrée)

Figure C.6 : Prédiction automatique du risque d'inondation (composante Random Forest intégrée)

Table Des Matières

Dédicace	ii
Remerciements	iii
SIGLES ET ABRÉVIATIONS	iv
Liste Des Figures	v
Liste Des Tableaux	vi
Sommaires	viii
Abstract	11
Introduction Generale	12
1. Contexte et Problématique	13
2. Objectifs du Travail	14
3. Contributions Originales	14
4. Principaux Résultats	15
5. Structure du Mémoire	15
Chapitre 1 : État De l'Art	17
1.1 Les Inondations au Sénégal : Enjeux, Évolution et Spécificités	18
1.2 Réponses Institutionnelles et Initiatives Citoyennes	19
1.3 Machine Learning et Prédiction des Inondations	20
1.3.1 Limites des Approches Hydrologiques Traditionnelles	20
1.3.2 Random Forest pour la Prédiction d'Inondations	20
1.4 Deep Learning et Détection Visuelle des Inondations	21
1.4.1 Évolution des Architectures CNN	21
1.4.2 Application à la Détection d'Inondations	22
1.4.3 ResNet-18 : Référence de Base	22
1.4.4 EfficientNet-B3 : Mise à l'Échelle Composée	23
1.4.5 Swin Transformer : Attention par Fenêtres Décalées	23
1.4.6 ConvNeXt-Tiny : Architecture Retenue	23
1.4.7 Explicabilité : Grad-CAM	24
1.5 Systèmes d'Alerte Précoce et Participation Citoyenne	24
1.6 Synthèse et Positionnement de ce Mémoire	25
Chapitre 2 : Approche méthodologique et contributions proposées	27
2.1 Cadre Expérimental et Métriques d'Évaluation	28
2.1.1 Métriques Adaptées au Problème d'Alerte : une Asymétrie Critique	28
2.1.2 Validation Croisée Temporelle (et non Aléatoire)	29
2.2 Composante 1 : Prédiction Météorologique par Random Forest	29
2.2.1 Données Brutes et Couverture Géographique	29
<i>Figure 2.1 : Séries temporelles des précipitations journalières par zone (2005–2025)</i>	31
2.2.2 Ingénierie des Variables Explicatives	31
<i>Figure 2.2 : Distribution des précipitations journalières et seuils-proxy d'inondation (P97 et P95 sur 3 j)</i>	32
2.2.3 Normalisation et Prévention des Fuites d'Information	32
2.2.4 Définition de la Variable Cible : Double Seuil par Percentile	33
2.2.5 Configuration du Random Forest et Justification des Hyperparamètres	33
2.3 Composante 2 : Détection Visuelle par Réseaux de Neurones Convolutifs	34

Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche intégrée basée sur le machine learning, le deep learning et la participation citoyenne

2.3.1 Constitution et Caractéristiques du Dataset d'Images	34
2.3.2 Stratégie d'Augmentation des Données	35
2.3.3 Normalisation ImageNet et Redimensionnement	36
2.3.4 Les Quatre Architectures Comparées	36
2.3.5 Transfer Learning en Trois Phases Progressives	38
2.3.6 Stratégie de Régularisation Anti-Surapprentissage	39
2.4 Protocole Expérimental Unifié	39
2.4.1 Partitionnement des Données	39
2.4.2 Reproductibilité	40
2.5 Synthèse des Contributions Méthodologiques	40
Chapitre 3: Expérimentations et résultats	41
3.1 Résultats de la Prédiction Météorologique (Random Forest)	42
3.1.1 Performances sur l'Ensemble de Test (2023–2025)	42
3.1.2 Importance des Variables	43
3.1.3 Validation Croisée Temporelle — 5 Folds (2008–2022)	44
3.1.4 Matrice de Confusion sur le Test Final	45
3.2 Résultats de la Détection Visuelle par Réseaux Convolutifs	47
3.2.1 Dataset et Protocole	47
3.2.2 ResNet-18 — Référence de Base	47
3.2.3 EfficientNet-B3 — Trois Phases Complètes	49
3.2.4 ConvNeXt-Tiny — Modèle Retenu	50
3.2.5 Swin-Tiny — Meilleur Rappel, Early Stop en Phase 2	52
3.2.6 Comparaison des Quatre Architectures	53
3.3 Visualisations Grad-CAM (Cellule 21)	56
3.4 Discussion	57
3.4.1 Pourquoi ConvNeXt-Tiny plutôt que Swin-Tiny ?	57
3.4.2 Comparaison avec la Littérature	58
3.4.3 Limitations	58
3.5 Synthèse des Résultats	59
Conclusion Générale	61
1. Rappel de la Problématique et des Objectifs	62
2. Bilan des Résultats Obtenus	62
3. Contributions Principales	63
4. Limites et Travaux Futurs	63
5. Réflexion Finale	64
BIBLIOGRAPHIE	65
Annexes	I
ANNEXE A — Détails Méthodologiques et Résultats Complémentaires du Modèle Random Forest	III
A.1 — Source et Période des Données	III
A.2 — Variables Explicatives Sélectionnées (SELECTED_FEATURES)	III
A.3 — Répartition des Données d'Apprentissage et de Test	IV
A.4 — Hyperparamètres du Modèle Random Forest	V
A.5 — Performances Globales sur le Jeu de Test	V
A.6 — Matrice de Confusion Détaillée	VI
A.7 — Importance des Variables (Gini)	VI
A.8 — Validation Croisée Temporelle (TimeSeriesSplit, 5 Folds)	VII
A.9 — Extraits de Code Clé (model.ipynb)	VII

**Détection et prédiction des inondations au Sénégal par intelligence artificielle : approche
intégrée basée sur le machine learning, le deep learning et la participation citoyenne**

A.9.1 — SELECTED_FEATURES et seuil de décision (Cellule 4 et Cellule 42)	VII
A.9.2 — Configuration et entraînement du Random Forest (Cellule 21)	VIII
A.9.3 — Organisation des fichiers	VIII
ANNEXE B — Détails Méthodologiques et Résultats Complémentaires de la Comparaison CNN ...	IX
B.1 — Constitution du Jeu de Données d'Images	IX
B.2 — Prétraitement et Augmentation des Données	X
B.3 — Configuration d'Entraînement Commune aux 4 Modèles (CONFIG)	XI
B.4 — Architecture FloodClassifier et Protocole 3 Phases	XI
B.5 — Résultats Complètes des 4 Architectures (Cellule 15)	XII
B.6 — Couches Cibles Grad-CAM (Cellule 21)	XIII
B.7 — Organisation des Fichiers et Reproductibilité	XIII
ANNEXE C — Plateforme Collaborative de Signalement et d'Aide à la Décision	XV
C.1 — Objectifs Fonctionnels de la Plateforme	XV
C.2 — Rôles et Profils Utilisateurs	XV
C.3 — Architecture Technique de la Plateforme	XVI
C.4 — Flux de Traitement d'un Signalement	XVI
C.5 — Données Géographiques et Visualisation	XVII
C.6 — Sécurité, Traçabilité et Limites	XVII
C.7 — Reproductibilité et Extension	XVII
C.8 — Illustrations de la Plateforme (Captures d'Écran)	XVIII
Table Des Matières	XXIV